

Lecture 03: 语音信号处理基础

预处理与特征提取

王帅

南京大学智能科学与技术学院

2026 年 9 月 11 日



南京大學
NANJING UNIVERSITY



智能科学与技术学院
School of Intelligence Science and Technology

- ① 解释麦克风怎样把声音变成数字序列
- ② 根据采样率算出可保留的最高频率
- ③ 说明为什么语音要分帧、加窗并做 STFT
- ④ 读懂 log-Mel 频谱与 MFCC 的计算流程


本讲核心问题

我们不断回答同一个问题：**怎样把一段复杂的声音，变成模型容易使用的数字表示？**

1. 声音

1. 声音


- 空气压力随时间变化
- 麦克风输出连续电压
- 人耳能听，计算机还不能直接算



2. 数字表示

1. 声音

- 空气压力随时间变化
- 麦克风输出连续电压
- 人耳能听，计算机还不能直接算




2. 数字表示

- 采样、量化得到波形
- 分帧、STFT 得到时频图
- log-Mel / MFCC 作为**模型输入**


1. 声音

- 空气压力随时间变化
- 麦克风输出连续电压
- 人耳能听，计算机还不能直接算




2. 数字表示

- 采样、量化得到波形
- 分帧、STFT 得到时频图
- log-Mel / MFCC 作为**模型输入**




- **浊音**：近似周期，能量较高，例如元音 /a/




波形与频谱的对应关系

- **浊音**：近似周期，能量较高，例如元音 /a/
- **清音**：更像噪声，高频较多，例如 /s/、/f/



波形与频谱的对应关系

- **浊音**：近似周期，能量较高，例如元音 /a/
- **清音**：更像噪声，高频较多，例如 /s/、/f/
- **瞬态**：变化很快，例如 /p/、/t/ 的爆破




波形与频谱的对应关系

- **浊音**：近似周期，能量较高，例如元音 /a/
- **清音**：更像噪声，高频较多，例如 /s/、/f/
- **瞬态**：变化很快，例如 /p/、/t/ 的爆破

关键观察

同一句话会在这几种状态之间切换，所以整段语音不是平稳信号，只能分成短片段分析。



波形与频谱的对应关系

源-滤波器模型

激励源与声道滤波



南京大学
NANJING UNIVERSITY



智能科学与技术学院
School of Intelligence Science and Technology



声源系统

呼吸系统

肺部作为气泵，通过膈肌和肋间肌的运动提供动力气流

喉部结构

声带 (Vocal Folds) 是发声的关键器官，两片富有弹性的肌肉膜

声带振动

气流通过声带时，声带周期性振动

滤波器系统

声道结构

可变的谐振腔，从喉部上方延伸至嘴唇和鼻孔，包括咽腔、口腔和鼻腔

共振峰 (Formants)

声道内部空气柱发生共振，在特定频率上产生能量峰值

声道形状变化

不同形状导致不同共振峰频率，是区分不同音素的关键机制

浊音、清音与基频

声带振动决定清浊音与基频



南京大学
NANJING UNIVERSITY



智能科学与技术学院
School of Intelligence Science and Technology

🎤 浊音 (Voiced Sound)

声带处于适当张力并相互靠近，气流通过时引起声带周期性振动周期性振动产生基频 (F_0)

示例: 元音 (a, e, i, o, u)、辅音 (m, n, b, d, g, z, v)

🌀 轻音 (Unvoiced Sound)

声带张开，气流通过时不会引起声带振动，直接通过喉部形成湍流无明显的基频，声学特性更接近噪声


示例: 辅音 (p, t, k, f, s, h)

🎵 基频 (Fundamental Frequency, F_0)


基频决定了语音的音高，声带振动越快，音高越高

↑ 成人男性基频范围: 约80-120 Hz

↑ 成人女性基频范围: 约160-240 Hz



人类的发音是一个复杂而精妙的过程，主要涉及动力区、激励区和调制区三个部分的器官协同作用。



调制区由舌头、上齿、双唇、咽腔等组成。

- 舌头的前后位置、高低位置以及卷曲程度的不同，可以产生不同的元音和辅音。
- 上齿和双唇可以通过开合、紧闭、突出等动作，与气流相互作用，产生不同的爆破音、摩擦音和鼻音等辅音。

激励区包括喉头、气管和声带。

- 喉头又称喉结，由软骨、肌肉和韧带组成，内部有声带
- 气流从肺部经气管上升至喉头，声带根据发音需要振动或不振动


动力区主要由胸腔、肺和横膈膜组成。

- 肺是呼吸主要器官，发音时肺部呼出气流提供动力
- 横膈膜位于胸腔和腹腔之间，在发音过程中，通过收缩和放松来调节气流的强弱和稳定性。

- ① **能量**告诉我们哪里¹有声音，哪里可能是停顿。
- ② **周期性**提示声带是否规则振动，也和音高有关。
- ③ **过零率**粗略反映高频成分多少，清音通常比浊音高。
- ④ **过渡段**变化最快，往往携带辅音和音素边界的重要线索。

从声压到数字序列

麦克风、模数转换与 PCM




声压推动麦克风振膜，麦克风把振动变成连续电压。模数转换器 (ADC) 再按固定时间间隔测量电压，并把每次测量写成有限精度的数字，这就是 PCM 波形。

采样与量化


时间离散化与幅度离散化



采样前：时间连续、幅度连续



数字化后：时间离散、幅度离散



采样：时间离散化

量化：幅度离散化

奈奎斯特-香农采样定理 (Nyquist-Shannon Sampling Theorem)

为了无失真地从样本中恢复原始模拟信号，采样频率 f_s 必须至少是原始信号最高频率 $f_{\max}$ 的两倍。

奈奎斯特-香农采样定理 (Nyquist-Shannon Sampling Theorem)

为了无失真地从样本中恢复原始模拟信号，采样频率 f_s 必须至少是原始信号最高频率 $f_{\max}$ 的两倍。

$$f_s \geq 2 \cdot f_{\max}$$

奈奎斯特-香农采样定理 (Nyquist-Shannon Sampling Theorem)

为了无失真地从样本中恢复原始模拟信号，采样频率 f_s 必须至少是原始信号最高频率 $f_{\max}$ 的两倍。

$$f_s \geq 2 \cdot f_{\max}$$

应用实例

- **窄带电话**保留约 300–3400 Hz，常用 8 kHz 采样。

奈奎斯特-香农采样定理 (Nyquist-Shannon Sampling Theorem)

为了无失真地从样本中恢复原始模拟信号，采样频率 f_s 必须至少是原始信号最高频率 $f_{\max}$ 的两倍。

$$f_s \geq 2 \cdot f_{\max}$$

应用实例

- **窄带电话** 保留约 300–3400 Hz，常用 8 kHz 采样。
- **语音识别** 常用 16 kHz，可表示到接近 8 kHz 的成分。

奈奎斯特-香农采样定理 (Nyquist-Shannon Sampling Theorem)

为了无失真地从样本中恢复原始模拟信号，采样频率 f_s 必须至少是原始信号最高频率 $f_{\max}$ 的两倍。

$$f_s \geq 2 \cdot f_{\max}$$

应用实例

- **窄带电话**保留约 300–3400 Hz，常用 8 kHz 采样。
- **语音识别**常用 16 kHz，可表示到接近 8 kHz 的成分。
- **混叠例子**：8 kHz 采样时，6 kHz 正弦波会“伪装”成 2 kHz。

奈奎斯特-香农采样定理 (Nyquist-Shannon Sampling Theorem)

为了无失真地从样本中恢复原始模拟信号，采样频率 f_s 必须至少是原始信号最高频率 $f_{\max}$ 的两倍。

$$f_s \geq 2 \cdot f_{\max}$$

应用实例

- **窄带电话**保留约 300–3400 Hz，常用 8 kHz 采样。
- **语音识别**常用 16 kHz，可表示到接近 8 kHz 的成分。
- **混叠例子**：8 kHz 采样时，6 kHz 正弦波会“伪装”成 2 kHz。
- **生活类比**：电影中的车轮有时看起来倒转，也是离散采样造成的假象。

- 采样后，每个样本点的幅度值是连续的。

量化 (Quantization)

幅度维度的离散化

- 采样后，每个样本点的幅度值是连续的。
- 量化 (Quantization) 是用有限个离散电平来近似表示连续的幅度值。

量化 (Quantization)

幅度维度的离散化



- 采样后，每个样本点的幅度值是连续的。
- 量化 (Quantization) 是用有限个离散电平来近似表示连续的幅度值。
- 使用 B 个比特 (bit) 表示一个样本，则共有 2^B 个量化级别。

量化 (Quantization)

幅度维度的离散化




- 采样后，每个样本点的幅度值是连续的。
- 量化 (Quantization) 是用有限个离散电平来近似表示连续的幅度值。
- 使用 B 个比特 (bit) 表示一个样本，则共有 2^B 个量化级别。

量化 (Quantization)

幅度维度的离散化



- 采样后，每个样本点的幅度值是连续的。
- 量化 (Quantization) 是用有限个离散电平来近似表示连续的幅度值。
- 使用 B 个比特 (bit) 表示一个样本，则共有 2^B 个量化级别。



常见选择：16-bit PCM

16-bit 线性 PCM 是常见的语音波形存储格式。

- $B = 16$ ，提供 $2^{16} = 65,536$ 个量化级别。

量化误差 (Quantization Error)

$$e[n] = x_q[n] - x[n]$$

量化像“用整数刻度的尺子量长度”，刻度越细，误差通常越小。

例：16 kHz、16-bit、单声道 PCM

每秒样本数 = 16,000

每个样本 = 16 bit = 2 byte

每秒数据量 = $16,000 \times 2 = 32,000$ byte

- 1 秒原始语音约 32 kB，1 分钟约 1.92 MB（忽略文件头）。

例：16 kHz、16-bit、单声道 PCM

每秒样本数 = 16,000

每个样本 = 16 bit = 2 byte

每秒数据量 = $16,000 \times 2 = 32,000$ byte

- 1 秒原始语音约 32 kB，1 分钟约 1.92 MB（忽略文件头）。
- 双声道再乘 2；采样率或位深翻倍，数据量也翻倍。

核心假设：语音信号的短时平稳性 (Quasi-stationary)

语音信号整体不断变化，但在约 20 ms to 30 ms 内，声带和声道来不及发生很大变化，因此可以近似看成平稳信号。

核心假设：语音信号的短时平稳性 (Quasi-stationary)

语音信号整体不断变化，但在约 20 ms to 30 ms 内，声带和声道来不及发生很大变化，因此可以近似看成平稳信号。

为什么？

我们的发声器官（声带、舌头、嘴唇）的物理状态在短时间内不会发生剧烈变化。

怎么办？

将信号切分成很多短小的“帧” (Frame)，对每一帧进行独立分析。这就是 **分帧** 的思想。

核心假设：语音信号的短时平稳性 (Quasi-stationary)

语音信号整体不断变化，但在约 20 ms to 30 ms 内，声带和声道来不及发生很大变化，因此可以近似看成平稳信号。

为什么？

我们的发声器官（声带、舌头、嘴唇）的物理状态在短时间内不会发生剧烈变化。

怎么办？


将信号切分成很多短小的“帧” (Frame)，对每一帧进行独立分析。这就是 **分帧** 的思想。

经典预处理流程

去直流（常用） → 预加重（可选） → 分帧 → 加窗

为什么

语音频谱通常随频率升高而衰减。传统 MFCC 流程常用预加重减弱这种谱倾斜，让高频细节更显眼。



上：波形；下：频谱；左为处理前，右为处理后。


为什么

语音频谱通常随频率升高而衰减。传统 MFCC 流程常用预加重减弱这种谱倾斜，让高频细节更显眼。

一阶高通滤波器

$$y[n] = x[n] - \alpha x[n-1]$$

常见 $\alpha \approx 0.95-0.97$ 。它强调相邻样本的变化。



上：波形；下：频谱；左为处理前，右为处理后。

为什么

语音频谱通常随频率升高而衰减。传统 MFCC 流程常用预加重减弱这种谱倾斜，让高频细节更显眼。





一阶高通滤波器

$$y[n] = x[n] - \alpha x[n-1]$$

常见 $\alpha \approx 0.95-0.97$ 。它强调相邻样本的变化。

记住

预加重是传统流程中的可选项；是否使用，必须与模型训练配置一致。



上：波形；下：频谱；左为处理前，右为处理后。

分帧 (Framing)

- 帧长 (Frame Size): 通常为 20 ms to 30 ms。
(16 kHz 采样率下, 25 ms = **400** 个采样点)
- 帧移 (Frame Shift): 通常为 10 ms。
(16 kHz 采样率下, 10 ms = **160** 个采样点)
- 相邻帧通常重叠, 避免边界附近的信息只出现一次。

加窗 (Windowing)

- 问题: 突然截断会制造不真实的边缘, 使能量“漏”到附近频率。
- 方案: 乘以一个两端平滑过渡到零的窗函数, 如汉明窗。

分帧 (Framing)

- 帧长 (Frame Size): 通常为 20 ms to 30 ms。
(16 kHz 采样率下, 25 ms = **400** 个采样点)
- 帧移 (Frame Shift): 通常为 10 ms。
(16 kHz 采样率下, 10 ms = **160** 个采样点)
- 相邻帧通常重叠, 避免边界附近的信息只出现一次。

加窗 (Windowing)


- 问题: 突然截断会制造不真实的边缘, 使能量“漏”到附近频率。
- 方案: 乘以一个两端平滑过渡到零的窗函数, 如汉明窗。

类比

分帧像从长视频中截取一张张短镜头; 加窗像给每张镜头边缘做淡入淡出, 减少“硬切”造成的假信号。

帧长与采样点数

以 16 kHz 语音为例



帧长与帧移

$$N = 16,000 \times 0.025 = 400$$

$$H = 16,000 \times 0.010 = 160$$

- 每帧 400 点
- 每次前进 160 点
- 重叠 240 点 (60%)
- 1 秒约 100 帧

汉明窗 (Hamming Window)

对于一个长度为 N 的帧，窗函数 $w[n]$ 定义为：

$$w[n] = 0.54 - 0.46 \cos\left(\frac{2\pi n}{N-1}\right), \quad 0 \leq n \leq N-1$$

加窗后的信号 $x_w[n] = x[n] \cdot w[n]$ 。

汉明窗 (Hamming Window)

对于一个长度为 N 的帧，窗函数 $w[n]$ 定义为：

$$w[n] = 0.54 - 0.46 \cos\left(\frac{2\pi n}{N-1}\right), \quad 0 \leq n \leq N-1$$

加窗后的信号 $x_w[n] = x[n] \cdot w[n]$ 。

矩形窗 (Rectangular)

- $w[n] = 1$
- 优点：主瓣窄 (频率分辨率高)
- 缺点：**旁瓣高** (频谱泄漏严重)

汉明窗/汉宁窗

- 两端趋于 0
- 优点：**旁瓣低** (有效抑制频谱泄漏)
- 缺点：主瓣略宽 (频率分辨率稍低)

汉明窗 (Hamming Window)

对于一个长度为 N 的帧，窗函数 $w[n]$ 定义为：

$$w[n] = 0.54 - 0.46 \cos\left(\frac{2\pi n}{N-1}\right), \quad 0 \leq n \leq N-1$$

加窗后的信号 $x_w[n] = x[n] \cdot w[n]$ 。

矩形窗 (Rectangular)

- $w[n] = 1$
- 优点：主瓣窄 (频率分辨率高)
- 缺点：**旁瓣高** (频谱泄漏严重)

汉明窗/汉宁窗

- 两端趋于 0
- 优点：**旁瓣低** (有效抑制频谱泄漏)
- 缺点：主瓣略宽 (频率分辨率稍低)

语音处理中常见汉明窗或汉宁窗。具体选择应与特征提取器和训练配置保持一致。

时频分析的必要性

从时域波形到频域特征



南京大学
NANJING UNIVERSITY



智能科学与技术学院
School of Intelligence Science and Technology

时域分析的局限性

时域波形能告诉我们“什么时候响、振幅多大”，却不容易直接看出声音由哪些频率组成。就像只看钢琴琴弦的总振动，很难判断同时按下了哪些琴键。

时频分析的必要性

从时域波形到频域特征



南京大学
NANJING UNIVERSITY



智能科学与技术学院
School of Intelligence Science and Technology

时域分析的局限性

时域波形能告诉我们“什么时候响、振幅多大”，却不容易直接看出声音由哪些频率组成。就像只看钢琴琴弦的总振动，很难判断同时按下了哪些琴键。

分析频率成分

频谱把复杂波形拆成许多不同频率的正弦分量。元音的若干共振峰、清音的高频能量，都能在频谱中看得更清楚。

目标：既要知道有哪些频率，也要知道它们在什么时候出现。

短时傅里叶变换 (STFT)

时变频谱的短时分析



南京大学
NANJING UNIVERSITY



智能科学与技术学院
School of Intelligence Science and Technology

基本原理：语音的短时平稳性 (Short-Time Stationarity)

整句话的频率成分不断变化，但每个 20–30 ms 小片段可以近似看成“不变”。

短时傅里叶变换 (STFT)

时变频谱的短时分析



基本原理：语音的短时平稳性 (Short-Time Stationarity)

整句话的频率成分不断变化，但每个 20–30 ms 小片段可以近似看成“不变”。

STFT：滑动窗口分析法

STFT 的过程就像用一个“探照灯”（窗函数）在时间轴上滑动：

- ① 分帧 (Framing): 将信号切分成一系列有重叠的短时帧。

横轴看时间，纵轴看频率，颜色深浅看能量。

短时傅里叶变换 (STFT)

时变频谱的短时分析



基本原理：语音的短时平稳性 (Short-Time Stationarity)

整句话的频率成分不断变化，但每个 20–30 ms 小片段可以近似看成“不变”。

STFT：滑动窗口分析法

STFT 的过程就像用一个“探照灯”（窗函数）在时间轴上滑动：

- ① 分帧 (Framing): 将信号切分成一系列有重叠的短时帧。
- ② 加窗 (Windowing): 对每一帧乘以一个窗函数，以平滑帧的边缘。

横轴看时间，纵轴看频率，颜色深浅看能量。

短时傅里叶变换 (STFT)

时变频谱的短时分析



基本原理：语音的短时平稳性 (Short-Time Stationarity)

整句话的频率成分不断变化，但每个 20–30 ms 小片段可以近似看成“不变”。

STFT：滑动窗口分析法

STFT 的过程就像用一个“探照灯”（窗函数）在时间轴上滑动：

- ① 分帧 (Framing): 将信号切分成一系列有重叠的短时帧。
- ② 加窗 (Windowing): 对每一帧乘以一个窗函数，以平滑帧的边缘。
- ③ 变换 (Transform): 对每一帧计算 FFT，得到这一小段的频谱。

横轴看时间，纵轴看频率，颜色深浅看能量。

短时傅里叶变换 (STFT)

时变频谱的短时分析



基本原理：语音的短时平稳性 (Short-Time Stationarity)

整句话的频率成分不断变化，但每个 20–30 ms 小片段可以近似看成“不变”。

STFT：滑动窗口分析法

STFT 的过程就像用一个“探照灯”（窗函数）在时间轴上滑动：

- ① 分帧 (Framing): 将信号切分成一系列有重叠的短时帧。
- ② 加窗 (Windowing): 对每一帧乘以一个窗函数，以平滑帧的边缘。
- ③ 变换 (Transform): 对每一帧计算 FFT，得到这一小段的频谱。
- ④ 组合 (Combine): 把各帧的幅度或功率谱按时间排列，形成**声谱图 (Spectrogram)**。


横轴看时间，纵轴看频率，颜色深浅看能量。

STFT 公式

在时间点 m 和频率点 k 的 STFT 值 $X(m, k)$ 定义为：


$$X(m, k) = \sum_{n=0}^{N-1} x[n + mH] \cdot w[n] \cdot e^{-j\frac{2\pi kn}{N_{FFT}}}$$

- N : 一帧有多少采样点； H : 相邻两帧相隔多少点
- $w[n]$: 窗函数； N_{FFT} : FFT 点数，通常不小于 N
- 例: $f_s = 16$ kHz、 $N = 400$ 、 $H = 160$ 、 $N_{FFT} = 512$
- 此时相邻频率格点间隔为 $f_s/N_{FFT} = 31.25$ Hz




● 横轴：时间


声谱图的解读




- 横轴：时间
- 纵轴：频率




- 横轴：时间
- 纵轴：频率
- 颜色：该处能量大小



- 横轴：时间
- 纵轴：频率
- 颜色：该处能量大小
- 横向亮带：共振峰



- 横轴：时间
- 纵轴：频率
- 颜色：该处能量大小
- 横向亮带：共振峰
- 短促竖纹：爆破或瞬态



- 横轴：时间
- 纵轴：频率
- 颜色：该处能量大小
- 横向亮带：共振峰
- 短促竖纹：爆破或瞬态

读图练习

先找有声区，再看低频谐波和共振峰；最后寻找高频摩擦与短时爆破。这样比盯着一维波形更容易定位语音事件。

短窗

- 能看清爆破音等快速变化
- 频率峰较模糊
- 像高速快门：动作清楚，进光较少

长窗

- 频率峰更容易分开
- 容易抹平快速变化
- 像慢速快门：细节更多，动作可能拖影

短窗

- 能看清爆破音等快速变化
- 频率峰较模糊
- 像高速快门：动作清楚，进光较少

长窗

- 频率峰更容易分开
- 容易抹平快速变化
- 像慢速快门：细节更多，动作可能拖影

语音中的常用折中

20–30 ms 的窗长既能近似满足短时平稳，又能分辨主要谐波和共振峰。增加零填充会让频率格点更密，但不会突破窗长决定的真实分辨能力。

输入信号	使用的变换	输出频率轴
连续时间 $x(t)$	CTFT	连续
离散时间、概念上无限长 $x[n]$	DTFT	连续且周期
离散时间、有限长一帧	DFT	N 个离散频率格点

输入信号	使用的变换	输出频率轴
连续时间 $x(t)$	CTFT	连续
离散时间、概念上无限长 $x[n]$	DTFT	连续且周期
离散时间、有限长一帧	DFT	N 个离散频率格点

计算机真正算什么？

录音已经采样，而且每次只处理有限长的一帧，所以实际计算的是 DFT；FFT 只是更快的 DFT 算法。

3. 离散傅里叶变换 (DFT) 与快速傅里叶变换 (FFT)

- 输入是一帧 N 点信号，输出 N 个复数频率系数。

$$X[k] = \sum_{n=0}^{N-1} x[n] e^{-j \frac{2\pi kn}{N}}$$

- $|X[k]|$ 表示第 k 个频率格点的幅度，相位由复数角度给出。
- 功率谱常写作 $P[k] = |X[k]|^2 / N$ 。语音特征通常先关注功率，再做感知尺度压缩。
- FFT 将计算量从 $O(N^2)$ 降到 $O(N \log N)$ 。

核心思想

MFCC (Mel-Frequency Cepstral Coefficients) 用 Mel 尺度近似描述人耳对频率间隔的感知，再用对数和 DCT 得到紧凑的频谱包络表示。

核心思想

MFCC (Mel-Frequency Cepstral Coefficients) 用 Mel 尺度近似描述人耳对频率间隔的感知，再用对数和 DCT 得到紧凑的频谱包络表示。

MFCC 提取全流程

波形 $\rightarrow$ 分帧加窗 $\rightarrow$ FFT 功率谱 $\rightarrow$ Mel 滤波器组 $\rightarrow$ 取对数 $\rightarrow$ DCT

核心思想


MFCC (Mel-Frequency Cepstral Coefficients) 用 Mel 尺度近似描述人耳对频率间隔的感知，再用对数和 DCT 得到紧凑的频谱包络表示。

MFCC 提取全流程


波形 $\rightarrow$ 分帧加窗 $\rightarrow$ FFT 功率谱 $\rightarrow$ Mel 滤波器组 $\rightarrow$ 取对数 $\rightarrow$ DCT

直观理解


功率谱像高分辨率照片；Mel 滤组把相邻频率合并；对数压缩明暗范围；DCT 再用少量系数概括整体轮廓。




- 每个三角滤波器汇总一小段频率的能量。



- 每个三角滤波器汇总一小段频率的能量。
- 低频滤波器更密，高频滤波器更疏。



- 每个三角滤波器汇总一小段频率的能量。
- 低频滤波器更密，高频滤波器更疏。
- 这是一种受听觉启发的近似，不是完整的人耳模型。



- 每个三角滤波器汇总一小段频率的能量。
- 低频滤波器更密，高频滤波器更疏。
- 这是一种受听觉启发的近似，不是完整的人耳模型。

Mel 尺度

$$\text{mel}(f) = 2595 \log_{10} \left(1 + \frac{f}{700} \right)$$

类比钢琴：低音区相邻音的频率差较小，高音区较大。

步骤 4: 计算对数能量

将功率谱与每个梅尔滤波器相乘再求和，得到每个滤波器的输出能量 E_i ，然后取对数。

$$S[i] = \ln \left(\sum_k P[k] M_i[k] \right)$$

- $M_i[k]$ 是第 i 个梅尔滤波器。

步骤 4: 计算对数能量

将功率谱与每个梅尔滤波器相乘再求和，得到每个滤波器的输出能量 E_i ，然后取对数。

$$S[i] = \ln \left(\sum_k P[k] M_i[k] \right)$$

- $M_i[k]$ 是第 i 个梅尔滤波器。
- 对数压缩动态范围，使强能量不至于淹没较弱但有用的结构。

步骤 4: 计算对数能量

将功率谱与每个梅尔滤波器相乘再求和，得到每个滤波器的输出能量 E_i ，然后取对数。

$$S[i] = \ln \left(\sum_k P[k] M_i[k] \right)$$

- $M_i[k]$ 是第 i 个梅尔滤波器。
- 对数压缩动态范围，使强能量不至于淹没较弱但有用的结构。
- 例：能量 10 和 1000 相差 100 倍；取自然对数后约为 2.3 和 6.9。

步骤 5: 离散余弦变换 (DCT)

相邻 Mel 频带的能量往往相似。DCT 把这条平滑曲线换一组坐标表示，使主要变化集中在前几个系数。

$$c[n] = \sum_{i=1}^K S[i] \cos \left(\frac{\pi n(i-0.5)}{K} \right)$$

- K 是 Mel 滤波器数量， n 是倒谱系数编号。

步骤 5: 离散余弦变换 (DCT)

相邻 Mel 频带的能量往往相似。DCT 把这条平滑曲线换一组坐标表示，使主要变化集中在前几个系数。

$$c[n] = \sum_{i=1}^K S[i] \cos \left(\frac{\pi n(i-0.5)}{K} \right)$$

- K 是 Mel 滤波器数量， n 是倒谱系数编号。
- 传统语音识别常保留前 12-13 个系数，再按需要加入帧能量。

步骤 5: 离散余弦变换 (DCT)

相邻 Mel 频带的能量往往相似。DCT 把这条平滑曲线换一组坐标表示，使主要变化集中在前几个系数。

$$c[n] = \sum_{i=1}^K S[i] \cos \left(\frac{\pi n(i-0.5)}{K} \right)$$

- K 是 Mel 滤波器数量， n 是倒谱系数编号。
- 传统语音识别常保留前 12-13 个系数，再按需要加入帧能量。
- 低阶系数描述频谱的整体包络，高阶系数更关注细碎变化。

为什么需要动态特征？

单帧 MFCC 只描述当前时刻。音素区别常体现在前后几帧怎样变化，例如“ba”和“da”的共振峰过渡不同。

为什么需要动态特征？

单帧 MFCC 只描述当前时刻。音素区别常体现在前后几帧怎样变化，例如“ba”和“da”的共振峰过渡不同。

一阶差分近似

$$\Delta c_t \approx \frac{c_{t+1} - c_{t-1}}{2}$$

- Delta 近似“速度”，Delta-Delta 近似“加速度”。

为什么需要动态特征？

单帧 MFCC 只描述当前时刻。音素区别常体现在前后几帧怎样变化，例如“ba”和“da”的共振峰过渡不同。

一阶差分近似

$$\Delta c_t \approx \frac{c_{t+1} - c_{t-1}}{2}$$

- Delta 近似“速度”，Delta-Delta 近似“加速度”。
- 实际计算常综合前后多帧，减少偶然抖动。

传统系统中的常见配置

一个常见的历史配置由 39 维组成：

- 13 维静态 MFCC (12 个系数 + 1 个能量项)
- 13 维 **Delta 特征** (速度)
- 13 维 **Delta-Delta 特征** (加速度)

传统系统中的常见配置

一个常见的历史配置由 39 维组成：

- 13 维静态 MFCC (12 个系数 + 1 个能量项)
- 13 维 **Delta 特征** (速度)
- 13 维 **Delta-Delta 特征** (加速度)

维数并非固定

MFCC 数量、是否加入能量和差分都由系统配置决定。现代神经网络也常直接使用 log-Mel 频谱，不再计算 DCT 和显式 Delta。

均值方差归一化 (CMVN)

对每个特征维度减去均值，并按标准差缩放：

$$\hat{x}_{t,d} = \frac{x_{t,d} - \mu_d}{\sigma_d + \varepsilon}$$

- 同一句话录得更响，不应该被模型误认为内容不同。

均值方差归一化 (CMVN)

对每个特征维度减去均值，并按标准差缩放：

$$\hat{x}_{t,d} = \frac{x_{t,d} - \mu_d}{\sigma_d + \varepsilon}$$

- 同一句话录得更响，不应该被模型误认为内容不同。
- 不同麦克风会带来固定的频谱偏差，归一化可减弱这类影响。

均值方差归一化 (CMVN)

对每个特征维度减去均值，并按标准差缩放：

$$\hat{x}_{t,d} = \frac{x_{t,d} - \mu_d}{\sigma_d + \varepsilon}$$

- 同一句话录得更响，不应该被模型误认为内容不同。
- 不同麦克风会带来固定的频谱偏差，归一化可减弱这类影响。
- 均值和方差可按句子、说话人或训练集统计，训练与测试必须采用同一规则。

① 采样与量化：把连续声压变成数字波形

- ① **采样与量化**：把连续声压变成数字波形
- ② **短时处理**：

- ① **采样与量化**：把连续声压变成数字波形
- ② **短时处理**：
 - 可选的去直流、预加重

- ① **采样与量化**：把连续声压变成数字波形
- ② **短时处理**：
 - 可选的去直流、预加重
 - 分帧 (25 ms 帧长, 10 ms 帧移)

① **采样与量化**：把连续声压变成数字波形

② **短时处理**：

- 可选的去直流、预加重
- 分帧 (25 ms 帧长, 10 ms 帧移)
- 加窗 (汉明窗)

- ① **采样与量化**: 把连续声压变成数字波形
- ② **短时处理**:
 - 可选的去直流、预加重
 - 分帧 (25 ms 帧长, 10 ms 帧移)
 - 加窗 (汉明窗)
- ③ **STFT**: 每帧 FFT, 得到随时间变化的功率谱

- ① **采样与量化**：把连续声压变成数字波形
- ② **短时处理**：
 - 可选的去直流、预加重
 - 分帧 (25 ms 帧长, 10 ms 帧移)
 - 加窗 (汉明窗)
- ③ **STFT**：每帧 FFT，得到随时间变化的功率谱
- ④ **感知压缩**：

- ① **采样与量化**: 把连续声压变成数字波形
- ② **短时处理**:
 - 可选的去直流、预加重
 - 分帧 (25 ms 帧长, 10 ms 帧移)
 - 加窗 (汉明窗)
- ③ **STFT**: 每帧 FFT, 得到随时间变化的功率谱
- ④ **感知压缩**:
 - 梅尔滤波器组 $\rightarrow$ 对数能量

- ① **采样与量化**：把连续声压变成数字波形
- ② **短时处理**：
 - 可选的去直流、预加重
 - 分帧 (25 ms 帧长, 10 ms 帧移)
 - 加窗 (汉明窗)
- ③ **STFT**：每帧 FFT，得到随时间变化的功率谱
- ④ **感知压缩**：
 - 梅尔滤波器组 $\rightarrow$ 对数能量
 - 到这里得到 log-Mel 频谱；继续 DCT 得到 MFCC

- ① **采样与量化**：把连续声压变成数字波形
- ② **短时处理**：
 - 可选的去直流、预加重
 - 分帧 (25 ms 帧长, 10 ms 帧移)
 - 加窗 (汉明窗)
- ③ **STFT**：每帧 FFT，得到随时间变化的功率谱
- ④ **感知压缩**：
 - 梅尔滤波器组 $\rightarrow$ 对数能量
 - 到这里得到 log-Mel 频谱；继续 DCT 得到 MFCC
- ⑤ **可选后处理**：CMVN；传统系统还会加入 Delta 和 Delta-Delta

log-Mel 频谱

- 保留“时间 $\times$ Mel 频带”二维结构
- 适合 CNN、Transformer 等模型
- 现代 ASR 中很常见

MFCC

- 在 log-Mel 上继续做 DCT
- 用少量系数概括频谱包络
- 传统 GMM-HMM 系统中很常见

log-Mel 频谱

- 保留“时间 $\times$ Mel 频带”二维结构
- 适合 CNN、Transformer 等模型
- 现代 ASR 中很常见

MFCC

- 在 log-Mel 上继续做 DCT
- 用少量系数概括频谱包络
- 传统 GMM-HMM 系统中很常见

共同基础

两者都依赖采样、分帧、加窗、FFT 和 Mel 滤波器组。理解本节课，就理解了许多现代语音模型的输入端。

固定前端

波形 $\rightarrow$ log-Mel $\rightarrow$ 神经网络

例：Whisper 使用 16 kHz 音频和 log-Mel 频谱。

可学习前端

波形 $\rightarrow$ 卷积特征编码器 $\rightarrow$ 神经网络

例：wav2vec 2.0 从原始波形学习局部表示。

例子来源：Radford et al., 2022; Baevski et al., 2020。

固定前端

波形 $\rightarrow$ log-Mel $\rightarrow$ 神经网络

例：Whisper 使用 16 kHz 音频和 log-Mel 频谱。

可学习前端

波形 $\rightarrow$ 卷积特征编码器 $\rightarrow$ 神经网络

例：wav2vec 2.0 从原始波形学习局部表示。

“端到端”不等于“没有信号处理”

固定前端把知识写进算法；可学习前端让模型从数据中学滤波器。两条路线都在把波形变成更合适的表示。

例子来源：Radford et al., 2022; Baevski et al., 2020。

常见配置

16 kHz 音频, 25 ms 窗长, 10 ms 帧移, 80 个 Mel 频带。

- 原始波形约有 **16,000** 个样本。

常见配置

16 kHz 音频，25 ms 窗长，10 ms 帧移，80 个 Mel 频带。

- 原始波形约有 **16,000 个样本**。
- STFT 每 10 ms 产生一帧，所以 1 秒约有 **100 帧**。

常见配置

16 kHz 音频，25 ms 窗长，10 ms 帧移，80 个 Mel 频带。

- 原始波形约有 **16,000 个样本**。
- STFT 每 10 ms 产生一帧，所以 1 秒约有 **100 帧**。
- 80 维 log-Mel 特征约为 **100×80** 的矩阵。

常见配置

16 kHz 音频, 25 ms 窗长, 10 ms 帧移, 80 个 Mel 频带。

- 原始波形约有 **16,000 个样本**。
- STFT 每 10 ms 产生一帧, 所以 1 秒约有 **100 帧**。
- 80 维 log-Mel 特征约为 **100×80** 的矩阵。
- 每一行对应一个时刻, 每一列对应一个 Mel 频带。

常见配置

16 kHz 音频, 25 ms 窗长, 10 ms 帧移, 80 个 Mel 频带。

- 原始波形约有 **16,000 个样本**。
- STFT 每 10 ms 产生一帧, 所以 1 秒约有 **100 帧**。
- 80 维 log-Mel 特征约为 **100×80** 的矩阵。
- 每一行对应一个时刻, 每一列对应一个 Mel 频带。

压缩了什么? 保留了什么?

它不再保存每个采样点和相位细节, 但保留了模型最常用的短时频谱结构。

❶ 采样率越高，识别一定越准。 不一定；还要看原始带宽、训练数据和模型配置。

- ❶ 采样率越高，识别一定越准。 不一定；还要看原始带宽、训练数据和模型配置。
- ❷ FFT 点数越大，真实频率分辨率越高。 零填充让频率格点更密，真实分辨能力仍主要受窗长限制。

- ❶ **采样率越高，识别一定越准。** 不一定；还要看原始带宽、训练数据和模型配置。
- ❷ **FFT 点数越大，真实频率分辨率越高。** 零填充让频率格点更密，真实分辨能力仍主要受窗长限制。
- ❸ **声谱图就是 STFT。** STFT 是复数；常见声谱图显示它的幅度或功率，通常再转成 dB。

- ❶ **采样率越高，识别一定越准。** 不一定；还要看原始带宽、训练数据和模型配置。
- ❷ **FFT 点数越大，真实频率分辨率越高。** 零填充让频率格点更密，真实分辨能力仍主要受窗长限制。
- ❸ **声谱图就是 STFT。** STFT 是复数；常见声谱图显示它的幅度或功率，通常再转成 dB。
- ❹ **MFCC 永远是 39 维。** 39 维只是传统常见配置，现代系统常使用不同维数的 MFCC 或 log-Mel。

① 为什么 16 kHz 采样不能正确表示 10 kHz 正弦波？

- ① 为什么 16 kHz 采样不能正确表示 10 kHz 正弦波？
- ② 为什么语音分析常用 20–30 ms 的帧，而不是整句话做一次 FFT？

- ① 为什么 16 kHz 采样不能正确表示 10 kHz 正弦波？
- ② 为什么语音分析常用 20–30 ms 的帧，而不是整句话做一次 FFT？
- ③ 加窗解决什么问题？它带来了什么代价？

- ① 为什么 16 kHz 采样不能正确表示 10 kHz 正弦波？
- ② 为什么语音分析常用 20–30 ms 的帧，而不是整句话做一次 FFT？
- ③ 加窗解决什么问题？它带来了什么代价？
- ④ log-Mel 和 MFCC 在哪一步开始不同？

- ① 为什么 16 kHz 采样不能正确表示 10 kHz 正弦波？
- ② 为什么语音分析常用 20–30 ms 的帧，而不是整句话做一次 FFT？
- ③ 加窗解决什么问题？它带来了什么代价？
- ④ log-Mel 和 MFCC 在哪一步开始不同？
- ⑤ 为什么同一句话换一个麦克风后，常需要做归一化？

- ① 为什么 16 kHz 采样不能正确表示 10 kHz 正弦波？
- ② 为什么语音分析常用 20–30 ms 的帧，而不是整句话做一次 FFT？
- ③ 加窗解决什么问题？它带来了什么代价？
- ④ log-Mel 和 MFCC 在哪一步开始不同？
- ⑤ 为什么同一句话换一个麦克风后，常需要做归一化？

答案

奈奎斯特频率；短时平稳；泄漏与分辨率；DCT；设备与音量偏差。

- ① 采样决定时间精度和可表示的最高频率，量化决定位深。

- ① 采样决定时间精度和可表示的最高频率，量化决定位深。
- ② 语音整体非平稳，但短时间内可近似平稳。

- ① 采样决定时间精度和可表示的最高频率，量化决定位深。
- ② 语音整体非平稳，但短时间内可近似平稳。
- ③ 分帧、加窗、FFT 把波形变成随时间变化的频谱。

- ① 采样决定时间精度和可表示的最高频率，量化决定位深。
- ② 语音整体非平稳，但短时间内可近似平稳。
- ③ 分帧、加窗、FFT 把波形变成随时间变化的频谱。
- ④ log-Mel 保留二维时频结构；MFCC 再用 DCT 压缩频谱包络。

- ① 采样决定时间精度和可表示的最高频率，量化决定位深。
- ② 语音整体非平稳，但短时间内可近似平稳。
- ③ 分帧、加窗、FFT 把波形变成随时间变化的频谱。
- ④ log-Mel 保留二维时频结构；MFCC 再用 DCT 压缩频谱包络。
- ⑤ 现代系统可能使用固定前端，也可能从波形学习前端，但表示问题始终存在。