

智能语音技术 Project 选题与说明

算法改进、系统工程与跨学科声音智能

课程项目选题（参考）

2026 年 9 月 4 日

可以选择以下题目，也可以自行提出与智能语音/音频技术相关的题目。

Project 的基本定位与资源边界

算法改进

在固定 baseline 上改变一个关键因素，通过合理的数据划分、对照实验和消融验证贡献。

系统工程

调用已有模型形成端到端闭环，重点优化交互、延迟、稳定性、错误恢复和可解释性。

跨学科声音

将语音与音频方法用于心音、生态、睡眠等场景，明确任务边界和应用价值。

统一资源原则

优先使用公开数据和预训练模型；推荐冻结表征、训练轻量分类头、LoRA/Adapter 或直接做系统集成。除非已有充分基础，不建议从头训练大型生成模型。

- 建议 3-5 人组队，课程周期内完成；先用小子集跑通，再逐步扩展。
- “只调用一个 API” 不构成完整 Project，需要有明确的技术问题、系统设计或评测分析。

Demo 要求与评分标准

Demo 最低要求

- 支持“录音/上传 → 处理 → 播放或可视化 → 导出/保存日志”的完整闭环。
- 推荐 Gradio/Streamlit/Android/IOS 做快速原型；实时系统可使用 WebRTC、SoundDevice/PyAudio、FastAPI。
- 必须准备离线样例或录屏，以应对现场网络和设备问题。

评分建议

- 技术报告与可复现性 (**50%**): 问题定义、相关工作、数据划分、baseline、实验/消融、错误分析、代码与运行说明。
- 展示与答辩 (**50%**): 讲述清晰、Demo 完整、指标可信，能够解释设计选择、失败案例和局限。

1. Speech DeepFake Detection (语音伪造检测)

算法改进 | 资源：低-中

问题定义

检测一段语音是否由 TTS、VC 或局部编辑生成；重点考察模型面对未见生成器和压缩条件时的泛化能力。

最低可行版本

- 冻结 WavLM/wav2vec 2.0，仅训练轻量分类头。
- 按生成器或数据集划分训练与测试，避免随机切分泄漏。
- 比较谱图 CNN 与自监督表征，并做错误案例分析。

可选改进

- 域泛化：数据增强、特征归一化或对比学习。
- 加入不确定性与拒识，而非强制二分类。
- 扩展到合成器溯源或局部篡改定位。

数据、评测与 Demo

数据与评测：ASVspoof 2019/2021、WaveFake；EER、AUC、跨生成器性能和校准误差。

Demo：上传音频，显示真假概率、置信度及谱图证据；冻结编码器后单卡即可。

2. Voice Conversion (声音转换)

算法 + 系统 | 资源：中

问题定义

保持语义与节奏，仅改变说话人音色；不要求从头训练大型生成模型。

最低可行版本

- 复现“内容特征 + 说话人条件 + 声码器”的轻量管线。
- 只训练适配层/LoRA，比较 3 秒与 10 秒参考音频。
- 检查音色相似度提升是否损害可懂度。

可选改进

- 加入 F0、情感或韵律控制。
- 研究噪声参考音、跨语言或未见说话人的鲁棒性。
- 做流式分块推理和延迟分析。

数据、评测与 Demo

数据与评测：VCTK、LibriTTS、AISHELL-3 小子集；说话人相似度、CER/WER、F0 和主观听测。

Demo：录音/上传源语音，选择参考音色，完成转换、试听和下载。

3. Singing Voice Conversion (歌声转换)

生成 + 音乐 | 资源：中

问题定义

保留旋律与歌词，将演唱音色转换为目标歌手；重点分析音高保持和伴奏干扰。

最低可行版本

- 使用现成 SVC 模型，控制变量比较不同 F0 提取器。
- 在清唱小子集评估音高跟随、清浊音错误和歌词可懂度。
- 构造少量带伴奏样例，观察分离误差的传递。

可选改进

- 改进高音、转音、呼吸声等困难片段。
- 加入风格/力度控制或跨语言演唱转换。
- 研究少样本歌手适配。

数据、评测与 Demo

数据与评测：M4Singer、OpenCpop、NUS-48E 小子集；F0 RMSE、V/UV、CER、相似度和听测。

Demo：上传清唱，转换目标音色，并对齐显示转换前后的 F0。

4. Speaker Diarization (说话人日志)

算法改进 | 资源：低

问题定义

确定“谁在何时说话”，输出带时间戳的说话人标签，并区分 VAD、聚类和重叠带来的错误。

最低可行版本

- 使用预训练 ECAPA/x-vector + AHC 或谱聚类建立基线。
- 分别分析 VAD、聚类和重叠语音对 DER 的影响。
- 比较固定人数和未知人数两种设置。

可选改进

- 加入重叠检测或 cannot-link 约束。
- 做在线聚类，动态更新说话人原型并控制漂移。
- 注册少量已知说话人，实现说话人命名。

数据、评测与 Demo

数据与评测：AMI、VoxConverse、CALLHOME 小子集；DER/JER、说话人数误差和实时率。

Demo：上传会议录音，显示彩色时间轴，并导出 RTTM/JSON；多数实验无需训练主干。

5. Target Speech Extraction (目标语音提取)

算法改进 | 资源：中

问题定义

从多人混合语音中提取指定说话人，重点分析 enrollment 参考音频质量对结果的影响。

最低可行版本

- 复现轻量 SpeakerBeam/Conv-TasNet 条件提取基线。
- 改变 enrollment 长度、噪声、语义重叠和说话人相似度。
- 用下游 ASR 检验可懂度是否真正改善。

可选改进

- 加入 enrollment 质量估计或多参考融合。
- 比较说话人向量的不同注入层和注入方式。
- 做流式分块并报告算法延迟。

数据、评测与 Demo

数据与评测：Libri2Mix/WSJ0-2mix 子集；SI-SDRi、STOI、PESQ 和下游 WER。

Demo：输入混合音和 3-10 秒参考音，双轨播放目标语音与残差。

6. Whisper Speech to Normal Speech (耳语恢复)

语音恢复 | 资源：中

问题定义

为无基频的耳语补充音高和自然度，同时保持内容可懂和说话人特征。

最低可行版本

- 先做耳语增强或 Mel 转换，不追求大型端到端模型。
- 冻结内容编码器，只训练 F0/声学映射模块。
- 比较真实耳语和合成耳语的域差异。

可选改进

- 加入说话人保持或情感/语气控制。
- 使用 ASR 感知损失减少内容错误。
- 做端侧量化或小模型蒸馏。

数据、评测与 Demo

数据与评测：wTIMIT、CHAINS 或可获得的小规模耳语数据；CER/WER、F0、相似度和听测。

Demo：录制耳语，生成常规语音，并显示前后 Mel 与 F0；不建议从头训练声码器。

7. sEMG-to-Speech (肌电信号转语音)

跨模态 | 资源：中 | 数据先行

问题定义

由表面肌电预测音素、Mel 或语音；真正的难点是同步、跨被试和数据可得性。

最低可行版本

- 先做 sEMG 到音素/文本或 Mel 的离线任务。
- 对比 1D-CNN、BiLSTM 与小型 Transformer。
- 只选少量被试，明确说话人内或跨说话人划分。

可选改进

- 做跨被试适配或 few-shot 校准。
- 加入 VAD、音素边界等辅助任务。
- 探索模拟流式输入和端到端延迟。

数据、评测与 Demo

数据与评测：EMG-UKA 等公开数据；CER/WER、Mel 距离和对齐误差；定题前先确认数据可下载。

Demo：回放多通道 sEMG，输出文本/语音和同步波形；不要求自制硬件。

8. Speech-based Dialogue Agent (语音对话 Agent)

系统工程 | 资源：低

问题定义

构建“听-想-说”的可交互系统，并让延迟、打断和错误恢复能够被测量。

最低可行版本

- 使用级联 ASR → LLM/规则 → TTS，避免训练基础模型。
- 实现端点检测、实时转写、响应播放和会话日志。
- 选择一个明确场景，如课程问答、实验室助手或设备控制。

可选改进

- 加入 barge-in 打断、回声抑制和超时恢复。
- 比较云端与本地组件的时延和稳定性。
- 加入说话人身份、长期记忆或工具调用。

数据、评测与 Demo

数据与评测：自建 20-50 个任务脚本；任务成功率、首字延迟、端到端延迟和失败类型。

Demo：连续对话、实时字幕和延迟分解；主要工作量在系统设计。

9. Dialect Text-to-Speech (方言 TTS)

低资源生成 | 资源：中

问题定义

在少量方言数据下提高发音、声调和自然度，展示普通话/多语模型迁移的收益。

最低可行版本

- 选择已有开源数据的方言或口音，使用预训练 TTS 微调。
- 比较字、拼音/音素、方言标签等输入表示。
- 构建包含声调和变调现象的小测试集。

可选改进

- 研究 1/5/20 分钟数据量下的适配曲线。
- 加入 code-switch 或跨方言混读。
- 改进发音词典、文本正则化或可控韵律。

数据、评测与 Demo

数据与评测：公开方言语料或经授权的小规模自录；CER、声调准确率、相似度和听测。

Demo：输入文本，选择方言/说话人后合成；只微调适配层或轻量模型。

10. Automatic Voice Translation/Dubbing (自动化配音)

系统工程 | 资源：低-中

问题定义

将分离、识别、翻译、合成和混音连接为完整闭环，并重点处理译文时长与原视频同步。

最低可行版本

- 语音/视频 → ASR → 翻译 → TTS → 回混背景声。
- 限定单说话人、30-60 秒素材，先保证流程稳定。
- 保存中间结果，分析错误从哪一环开始传递。

可选改进

- 做译文长度控制和语速自适应。
- 加入说话人保持、情感保持或多人分轨。
- 比较不同组件组合的质量、速度和成本。

数据、评测与 Demo

数据与评测：公开视频或自录短片；ASR WER、翻译质量、音色相似度、时长偏差和主观评分。

Demo：上传短视频，选择目标语言，输出配音视频并支持原版/配音切换。

11. Heart Sound Analysis (心音检测)

跨学科：医工 | 资源：低

问题定义

识别正常/异常心音或心脏杂音，并探索模型关注的心动周期；课程项目仅做算法研究，不做临床诊断。

最低可行版本

- 将 PCG 转为 log-Mel，训练小型 CNN 或冻结音频编码器。
- 按患者划分训练/测试，严防同一患者数据泄漏。
- 输出心动周期或时间段热力图，解释模型关注位置。

可选改进

- 加入 S1/S2 分割、多实例学习或年龄/设备域适配。
- 研究噪声、听诊位置和设备变化下的鲁棒性。
- 加入置信度与拒识，提示低质量录音。

数据、评测与 Demo

数据与评测：PhysioNet/CinC 2016、CirCor DigiScope；AUC、F1、灵敏度/特异度和患者级评估。

Demo：上传心音，显示类别、置信度和心音图；使用小 CNN 或冻结表征即可。

12. Bird Sound Recognition (鸟声识别与生态监测)

跨学科：生态 | 资源：低

问题定义

从长时野外录音中识别鸟种/鸣叫事件，并统计时间、地点与物种活动，让分类结果服务生态监测。

最低可行版本

- 使用 BirdNET/PANNs/AST 特征，做冻结表征或轻量微调。
- 先选择 10-30 个物种，处理长尾和背景噪声。
- 按地点或录音设备做跨域测试，而不是随机切片。

可选改进

- 研究弱标签、多标签和罕见物种检测。
- 将片段预测聚合为全天物种活动曲线。
- 比较有/无地点与时间元数据时的泛化。

数据、评测与 Demo

数据与评测：BirdCLEF、BirdSet 或授权的 Xeno-canto 数据；macro-F1、mAP 和跨地点测试。

Demo：上传野外录音，输出物种时间轴、Top-k 和活动统计；冻结编码器即可。

13. Sleep Sound Monitoring (睡眠声音监测)

跨学科：健康 | 资源：低-中

问题定义

定位打鼾、呼吸、咳嗽和静音等事件，形成整夜时间轴；不直接宣称疾病诊断。

最低可行版本

- 先做 3-5 类声音事件检测，再进行分钟级统计。
- 比较 log-Mel CNN 与冻结通用音频表征。
- 接受试者划分，加入风扇、环境声和伴侣语音干扰。

可选改进

- 分析事件持续时间、周期性和异常片段。
- 研究手机距离、房间和设备变化下的鲁棒性。
- 只保留事件标签，探索隐私友好的本地处理。

数据、评测与 Demo

数据与评测：公开呼吸/睡眠声音子集或合规自录；event-F1、误报/小时和持续时间误差。

Demo：上传夜间音频，生成事件时间轴和统计摘要；明确结果不是医疗诊断。

14. Audio-Language Retrieval (音频-语言检索)

系统 + 表征 | 资源: 低

问题定义

输入自然语言描述, 从声音库中检索匹配片段; 也可反向为音频生成候选标签。

最低可行版本

- 使用预训练 CLAP, 不训练或只训练轻量投影层。
- 建立 500-2000 条的小型声音库和向量索引。
- 比较零样本检索、关键词检索和人工标签检索。

可选改进

- 研究中文查询或跨语言检索。
- 做难负例挖掘和校园/音乐/生态等领域适配。
- 在长音频中定位描述对应的时间区间。

数据、评测与 Demo

数据与评测: ESC-50、AudioCaps 小子集或自建合规声音库; Recall@K、mAP 和人工相关性。

Demo: 输入“雨声中有鸟叫”等描述, 返回匹配音频并试听; CPU/单卡可离线建索引。

15. On-device Sound Event Monitoring (端侧声音事件监测)

端侧系统 | 资源：低

问题定义

实时识别警报、玻璃破碎、敲门、婴儿哭声等事件，重点研究延迟、误报和持续运行稳定性。

最低可行版本

- 使用 YAMNet/PANNS 预训练模型，选择 5-10 类事件。
- 实现流式分帧、平滑、迟滞阈值和事件合并。
- 在 CPU 上测试实时率、内存和长期运行稳定性。

可选改进

- 做量化、蒸馏或 ONNX/TFLite 部署。
- 加入开放集拒识和用户自定义少样本事件。
- 在不同麦克风、距离和背景噪声下做压力测试。

数据、评测与 Demo

数据与评测：ESC-50、UrbanSound8K、AudioSet 子集；event-F1、误报/小时、检测延迟和 RTF。

Demo：麦克风实时输入，显示事件流、置信度和日志；无需训练大模型。

数据与工具入口（部分）

通用语音与音频

- ASVspoof: <https://www.asvspoof.org/>
- LibriMix: <https://github.com/JorisCos/LibriMix>
- WeSep: <https://github.com/wenet-e2e/WeSep>
- ESC-50: <https://github.com/karolpiczak/ESC-50>
- AudioSet: <https://research.google.com/audioset/>
- CLAP: <https://github.com/LAIION-AI/CLAP>

跨学科数据

- PhysioNet/CinC 2016: <https://physionet.org/content/challenge-2016/>
- CirCor Heart Sound: <https://physionet.org/content/circor-heart-sound/>
- BirdSet: <https://github.com/DBD-research-group/BirdSet>
- Xeno-canto: <https://xeno-canto.org/>
- UrbanSound8K: <https://urbansounddataset.weebly.com/urbansound8k.html>
- YAMNet: <https://www.tensorflow.org/hub/tutorials/yamnet>