Lecture 08：语音合成进阶（Advanced Speech Synthesis）

大模型时代：语音 token、语言模型、流匹配与可控合成

王帅

南京大学智能科学与技术学院

2026 年 10 月 30 日

上讲回顾：TTS 的四个核心难题

难题	要回答的问题	上一讲的代表方案
①读什么	多音字、数字、变调怎么读	文本前端：TN、G2P、韵律预测
②读多长	12 个音素对应多少帧	Tacotron 2 注意力；FastSpeech 时长预测
③怎么读	同一句话有无数种读法（一对多）	FastSpeech 2 补充音高、能量
④怎么发声	80 维 Mel 频谱 → 24000 个采样点	WaveNet → HiFi-GAN

上一讲讲到哪里

经典三段式：文本前端 → 声学模型 → 声码器，三个模块分别训练。

本讲从这里出发

先把三段合成一段（端到端），再看大模型如何重新回答这四个难题。

本节学习目标

1. 理解端到端模型 VITS 如何把声学模型和声码器合在一起训练
2. 说清大模型时代 TTS 的新目标：零样本克隆、可控合成、规模化数据、流式输出
3. 理解语音 **token** 是怎么来的：向量量化、RVQ、FSQ，语义 token 与声学 token 的区别
4. 掌握三条主流技术路线：语言模型式（VALL-E）、流匹配式（F5-TTS）、混合式（CosyVoice）
5. 了解可控合成的四类控制方式，以及大模型 TTS 的评价方法和风险

本讲核心问题

只给 3 秒钟录音和一句话描述，模型如何用这个人的声音、按我们要求的方式，读出任意一段文字？

本讲结构

承上启下

1. 端到端合成：VITS
2. 大模型时代：新目标与新范式
3. 把语音变成 token

三条技术路线

4. 语言模型式 TTS
5. 流匹配式 TTS
6. 混合式 TTS

控制、评价与展望

7. 可控语音合成
8. 大模型 TTS 怎么评价
9. 前沿方向与安全伦理

贯穿全讲的主线

新模型层出不穷，但都可以问三个问题：

- 中间表示是什么？(连续 / 离散)
- 用什么生成？(自回归 / 流匹配)
- 四个难题分别由谁负责？

目录

1. 端到端合成：VITS
2. 大模型时代：TTS 的新目标与新范式
3. 把语音变成 token
4. 路线一：语言模型式 TTS
5. 路线二：流匹配式 TTS
6. 路线三：混合式 TTS
7. 可控语音合成
8. 大模型 TTS 怎么评价
9. 前沿方向与安全伦理
10. 总结

为什么还要端到端？

两阶段系统的问题

- 训练与推理不匹配：声码器训练时看到的是真实 Mel，推理时却拿到声学模型预测的 Mel（更模糊）
- 通常要用预测的 Mel 再微调声码器
- 误差累积：两个模型分别训练，各自的误差叠加
- Mel 频谱这种人为设定的中间表示不一定是最优的

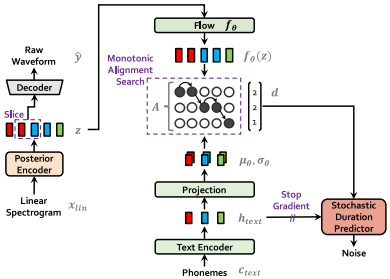
VITS（2021）的回答

- 一个模型：文本 $\rightarrow$ 波形
- 中间表示不再是 Mel，而是网络自己学到的隐变量 z
- 联合训练，没有不匹配问题
- 模型内部自动学对齐，不需要外部对齐器

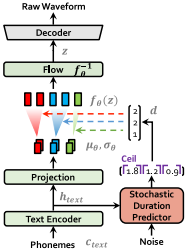
一句话概括

VITS = VAE（学隐变量）+ Flow（增强先验）+ GAN（提升音质）+ MAS（自动对齐）+ 随机时长（节奏多样）

VITS：训练与推理



训练：同时看文本和真实语音



推理：只有文本

核心思路

训练时：后验编码器从真实语音得到 z（“看答案”），先验编码器学习从文本预测 z 的分布，二者用 KL 散度拉近。

推理时：只用文本侧，预测时长 $\rightarrow$ 采样 $z \rightarrow$ 解码器直接输出波形。

VITS 的各个部件分别解决什么问题？

部件	做什么	对应难题
后验编码器	训练时从真实语音（线性谱）提取隐变量 z	提供学习目标
文本编码器 + Flow	从音素预测 z 的分布；Flow 让分布更灵活	③怎么读
单调对齐搜索（MAS）	动态规划找出文本与 z 的最佳单调对齐	②读多长
随机时长预测器	学习时长的分布，每次采样节奏略有不同	②③节奏多样
解码器（HiFi-GAN 生成器）	把 z 直接变成波形	④怎么发声
判别器	对抗训练，提升波形真实感	④音质

对比 FastSpeech 2

FastSpeech 2 的时长来自外部强制对齐器、是确定的；VITS 的时长在模型内部自动学到，而且是随机的，同一句话每次合成的节奏都可能略有不同，更像真人。

单调对齐搜索（MAS）：又见动态规划

目标

在所有单调、不跳跃的对齐 A 中，找到让隐变量似然最大的那个：

$$A^* = \arg\max_{A} \ \log p(z \mid c_{\text{text}}, A)$$

递推（i：音素，j：帧）

$$Q_{i,j} = \max\left(Q_{i-1,j-1},\, Q_{i,j-1}\right) + \log p(z_j \mid c_i)$$

第 j 帧要么继续读第 i 个音素，要么从第 $i-1$ 个音素前进到第 i 个。

得到时长

回溯得到对齐矩阵后，每个音素的时长就是它占了几帧：

$$d_i = \sum_j A_{i,j}$$

这些时长再用来训练时长预测器。

【回顾】这与第 04 讲 HMM 的维特比算法几乎一样：都是在“只能停留或前进”的约束下，用动态规划找最优路径。

VITS 的效果

系统（**LJSpeech**）	**MOS**	类型
真人录音	4.46	–
VITS	**4.43**	端到端
Glow-TTS + HiFi-GAN（声码器微调后）	4.14（4.32）	两阶段
Tacotron 2 + HiFi-GAN（声码器微调后）	3.77（4.25）	两阶段

从表中能读出什么？

- 括号里的提升说明两阶段系统确实存在训练-推理不匹配
- 端到端联合训练后，几乎追平真人录音

影响

VITS 结构紧凑、推理快，开源后被社区广泛使用，许多中文 TTS、歌声转换和“AI 角色配音”项目都基于它的变体。

VITS 之后，还缺什么？

2021 年的 TTS 能做到

- 在训练过的说话人上，音质接近真人
- 数据：几十到几百小时录音棚语音
- 风格：基本由训练数据决定

但实际应用想要

- 有声书：一本书几十个角色，各有声音和情绪
- 视频配音：换一种语言，声音不变、时长对齐画面
- 语音助手：边想边说，延迟要低
- 个性化：用我自己（或家人）的声音读

于是出现了四个新目标

1. 零样本：没见过的说话人，3 秒录音就能克隆
2. 可控：用标签、参考音频或一句话描述来指定情感、风格、语速
3. 规模化：用十万小时以上的真实语音训练
4. 流式：文字还没生成完，声音就开始播放

实现这些目标的关键工具：
借鉴大语言模型的做法

目录

1 端到端合成：VITS

2 大模型时代：TTS 的新目标与新范式

3 把语音变成 token

4 路线一：语言模型式 TTS

5 路线二：流匹配式 TTS

6 路线三：混合式 TTS

7 可控语音合成

8 大模型 TTS 怎么评价

9 前沿方向与安全伦理

10 总结

过去三年发生了什么？

数据

几十小时干净录音
⇓
数万到数百万小时真实语音（播客、视频、有声书）

能力

只能合成训练过的声音
⇓
3 秒参考音频即可克隆音色；跨语言；用自然语言描述控制风格

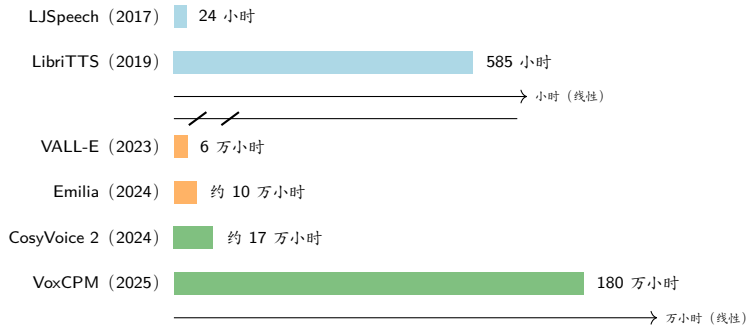
方法

回归连续的 Mel 频谱
⇓
把语音变成离散 token，用语言模型生成；或用流匹配从噪声生成

为什么是这三年？

大语言模型证明了“大数据 + 大模型 + 简单目标（预测下一个 **token**）”的威力；神经音频编解码器（2021–2022）让语音也能变成 token；扩散模型、流匹配在图像生成上成熟后被迁移到语音。

训练数据规模：十年增长约 10 万倍



下轴按真实比例：180 万小时约为 17 万小时的 10 倍。上下两段横轴不同，长度不能直接比较。

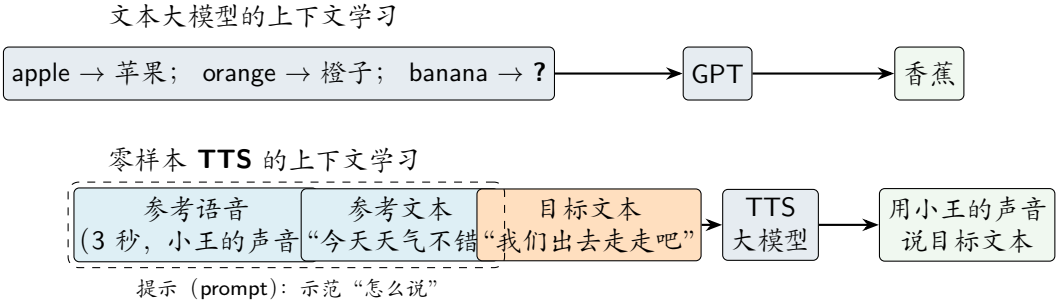
数据变了什么？

从专业播音员朗读，变成真实世界的说话：有口音、有情绪、有噪声、有笑声和停顿。

标注从哪来？

人工转写不可能。用 **ASR** 自动转写（第 04 讲），再按识别置信度、信噪比等自动过滤。

零样本 TTS：像 GPT 一样“照着提示说”



“零样本”是什么意思

目标说话人的声音从未出现在训练集中，也不做任何微调，只在推理时给一段参考音频。

和第 07 讲的多说话人 TTS 比

多说话人 TTS 用一个说话人向量表示音色，只学到音色。零样本 TTS 直接“续写”参考音频，连口音、语速、情绪、录音环境都会模仿。

可控 TTS：我们想控制哪些属性？

韵律（Prosody）

音高、时长、能量、停顿、重音

例：“这句话读慢一点，重读“明天””

情感（Emotion）

喜怒哀乐、情感强度

例：“带着哭腔，但强忍着”

语言（Language）

多语种、方言、口音、中英混说

例：“用四川话说”

音色（Timbre）

性别、年龄、嗓音质感、说话人身份

例：“一位声音沙哑的老人”

风格（Style）

新闻播报、讲故事、聊天、正式程度

例：“像深夜电台主播一样”

环境（Environment）

背景噪声、空间混响

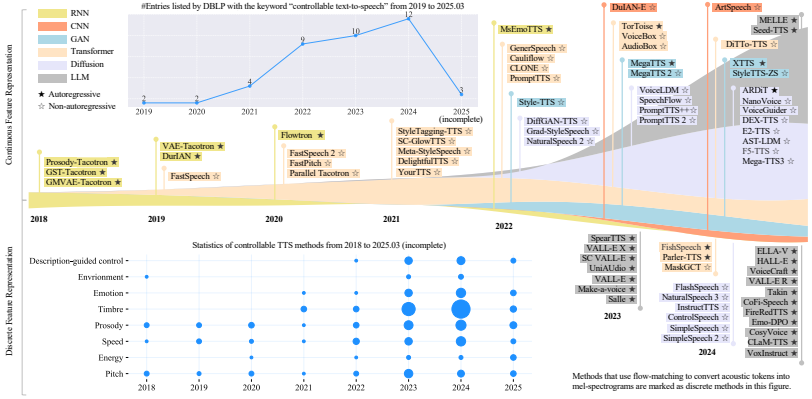
例：“像在海边打电话”

与上一讲的联系

这些属性几乎都属于难题③“怎么读”。FastSpeech 2 只能调音高、能量和语速三个数值；今天的目标是用任意方式、组合地控制所有这些属性。

分类参考：T. Xie et al., Towards Controllable Speech Synthesis in the Era of LLMs: A Systematic Survey, arXiv:2412.06602

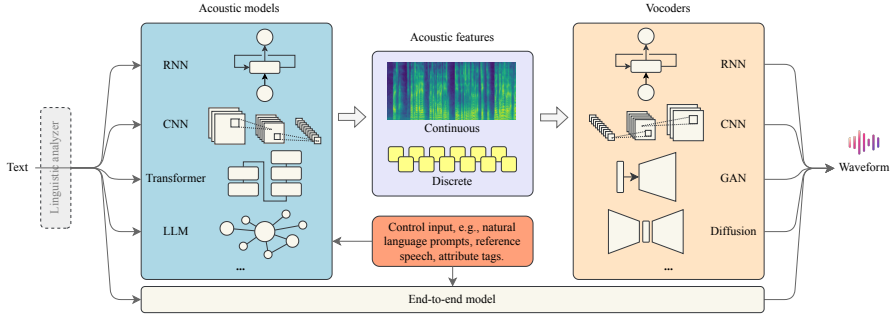
研究趋势一览



上半部分（连续特征）：RNN → Transformer → 扩散 / 流匹配

下半部分（离散 **token**）：2023 年起，基于 LLM 的方法快速增多

统一视角：现代 TTS 依然是“三段式”的影子



变了什么

- 声学模型可以是 **LLM**
- 中间表示可以是离散 **token**
- 多了一路控制输入：参考语音、描述、标签

没变什么

仍然是“声学模型 → 中间表示 → 声码器”；文本前端被大幅简化，很多模型直接输入字符或 BPE。

两种生成方式：自回归 vs 非自回归

自回归（AR）

一个一个地生成，每一步看前面所有输出：

$$P(\mathbf{y} \mid \mathbf{x}) = \prod_{t=1}^{T} P(y_t \mid y_{<t}, \mathbf{x})$$

- 长度由模型自己决定（生成结束符）
- 天然适合流式输出
- 慢；容易跳词、重复

【回顾】Tacotron 2 就是自回归

非自回归（NAR）

一次性（或迭代几步）并行生成整段：

$$\hat{\mathbf{y}} = f_\theta(\mathbf{x}), \quad \text{长度} T \text{ 需事先确定}$$

- 快、稳定
- 要回答“总长度从哪来”
- 需要生成模型（扩散、流匹配）来处理一对多

【回顾】FastSpeech 就是非自回归

本讲三条路线

语言模型式：AR 生成离散 token。　流匹配式：NAR 生成连续 Mel。　混合式：AR 负责“说什么、怎么断”，NAR 负责“声音细节”。

目录

1 端到端合成：VITS

2 大模型时代：TTS 的新目标与新范式

3 把语音变成 token

4 路线一：语言模型式 TTS

5 路线二：流匹配式 TTS

6 路线三：混合式 TTS

7 可控语音合成

8 大模型 TTS 怎么评价

9 前沿方向与安全伦理

10 总结

为什么要把语音变成离散 token？

语言模型只会做一件事

给定前文，预测下一个 token 在有限词表上的概率分布：

$$P(y_t = k \mid y_{<t}), \quad k \in \{1, \dots, K\}$$

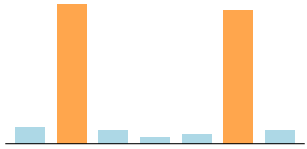
文字天然是离散的；语音是连续波形，需要先“离散化”。

离散化带来的好处

- 回归变分类：用交叉熵训练，比 MSE 更稳定
- 输出一个分布，可以采样：直接解决一对多
- 文本和语音进入同一个词表，可复用文本 LLM

【回顾】第 07 讲“平均的陷阱”：用 MSE 回归时，两种合理读法 $y = +1$ 和 $y = -1$ 会被平均成 $\hat{y} = 0$。

分类：预测分布再采样



两个读法都保留，采样时二选一，不会得到“平均”的模糊结果

基础：向量量化（Vector Quantization, VQ）

做法

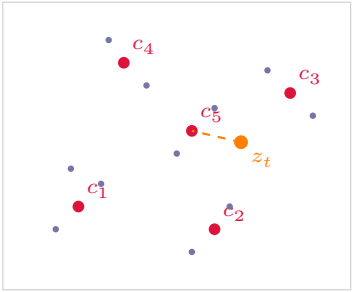
准备一个码本 $\mathcal{C} = \{c_1, \dots, c_K\}$（$K$ 个向量）。对每一帧的特征 z_t，找最近的码字，记下它的编号：

$$q_t = \arg\min_k \ \|z_t - c_k\|_2$$

编号 q_t 就是这一帧的 **token**；还原时用 c_{q_t} 近似 z_t。

直觉

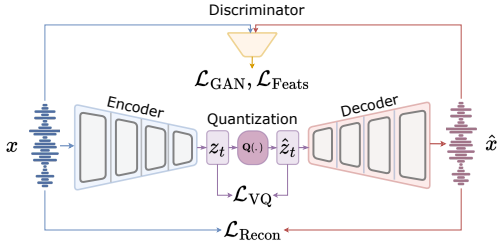
和 K-means 聚类一样：把连续空间切成 K 个区域，每个区域用一个“代表点”。$K = 1024$ 时，每个 token 携带 $\log_2 1024 = 10$ 比特信息。



z_t 离 c_5 最近 $\Rightarrow$ token $q_t = 5$

问题：一个码本表达能力有限。想要更精细，就要更大的 K，码本难训练，很多码字用不上（码本坍缩）。

神经音频编解码器（Neural Audio Codec）



三部分

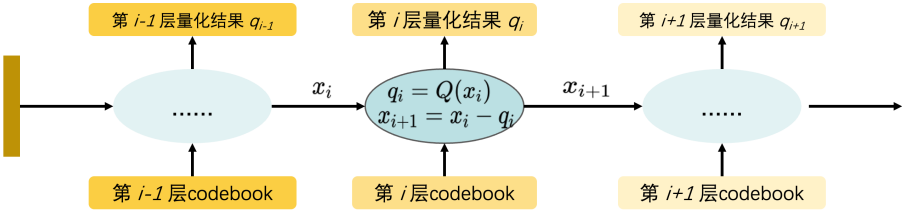
- 编码器：波形 → 每帧一个向量（卷积下采样）
- 量化器：向量 → token 编号
- 解码器：token → 波形

怎么训练

像自编码器一样“压缩再还原”：重建损失 + 量化损失 + **GAN** 对抗损失。【回顾】解码器本质上就是一个 HiFi-GAN 式的声码器（第 07 讲）。

代表：SoundStream（2021）、EnCodec（2022）、DAC（2023）、Mimi（2024）……

残差向量量化（RVQ）：先说个大概，再逐步补细节



算法

1. 残差初始化：$r^{(1)} = z_t$
2. 第 m 层：$q^{(m)} = \arg\min_k \|r^{(m)} - c_k^{(m)}\|$
3. 更新残差：$r^{(m+1)} = r^{(m)} - c_{q^{(m)}}^{(m)}$
4. 还原：$\hat{z}_t = \sum_{m=1}^{M} c_{q^{(m)}}^{(m)}$

类比：用不同面额凑出 87.6 元

先用 50 元一张凑（取 2 张 = 100，差 -12.4），再用 5 元修正（-10，差 -2.4），再用 1 元修正……每一层只负责上一层没表达好的部分。

第 1 层最重要（粗略轮廓），后面的层补充细节。层数越多，音质越好、token 越多。

手算一次 RVQ

题目

一维特征 $z = 0.83$，三层码本分别为：$\mathcal{C}^{(1)} = \{0,\ 0.5,\ 1.0\}$，$\mathcal{C}^{(2)} = \{-0.25,\ 0,\ 0.25\}$，$\mathcal{C}^{(3)} = \{-0.1,\ 0,\ 0.1\}$。
求每一层选中的码字、残差，以及最终的重建值。

手算一次 RVQ

题目

一维特征 $z = 0.83$，三层码本分别为：$\mathcal{C}^{(1)} = \{0,\ 0.5,\ 1.0\}$，$\mathcal{C}^{(2)} = \{-0.25,\ 0,\ 0.25\}$，$\mathcal{C}^{(3)} = \{-0.1,\ 0,\ 0.1\}$。
求每一层选中的码字、残差，以及最终的重建值。

层	当前残差	选中码字	新残差
1	0.83	1.0	-0.17
2	-0.17	-0.25	0.08
3	0.08	0.1	-0.02

结论

重建值 $\hat{z} = 1.0 - 0.25 + 0.1 = 0.85$。误差随层数下降：$0.17 \to 0.08 \to 0.02$。每层只有 3 个码字，三层组合起来却能表示 $3^3 = 27$ 种值。

算一算：一段语音变成多少个 token？

以 EnCodec（VALL-E 使用的配置）为例

24 kHz 采样，编码器下采样 320 倍；8 层 RVQ，每层码本 1024 个码字。

算一算：一段语音变成多少个 token？

以 EnCodec（VALL-E 使用的配置）为例

24 kHz 采样，编码器下采样 320 倍；8 层 RVQ，每层码本 1024 个码字。

计算

- 帧率：$24000/320 = 75$ 帧/秒
- 每帧 8 个 token，每个 $\log_2 1024 = 10$ 比特
- 码率：$75 \times 8 \times 10 = 6000$ bit/s $= 6$ kbps
- 10 秒语音：$750 \times 8 = 6000$ 个 token

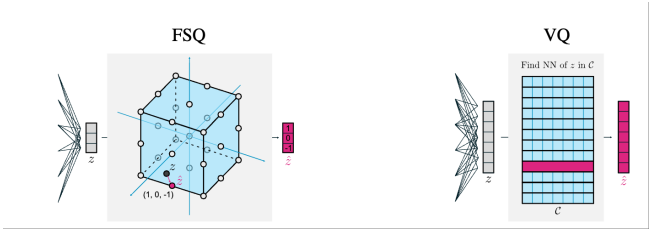
对比

- 16 bit PCM：$24000 \times 16 = 384$ kbps，压缩 64 倍
- 同样 10 秒中文朗读，大约只有 40 个汉字
- 语音 token 序列比文本长一百多倍，语言模型生成起来又慢又难

于是有了后来的改进方向

降低帧率（如 CosyVoice 2 每秒 25 个 token）、减少码本层数（只用 1 层）、让 token 只保留“说了什么”而不保留全部声学细节。

有限标量量化（FSQ）：不要码本，直接四舍五入



做法

1. 把特征投影到很低的维度 D（如 8 维）
2. 每一维压到 $[-K, K]$ 并四舍五入到整数
3. 所有维度的取值组合就是 token：共 $(2K+1)^D$ 种

例：$K=1$、$D=3$ 时，$(0.7, -0.2, -0.9) \to (1, 0, -1)$，共 $3^3 = 27$ 种 token

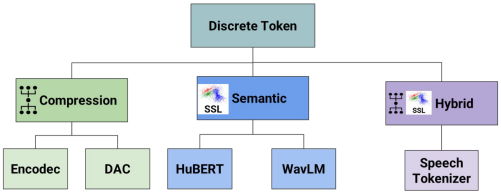
为什么好用

码本是“隐式”的网格，不用学习，每个格点都能用上。CosyVoice 2 的对比：

	码本大小	实际使用
VQ	4096	963（23%）
FSQ	6561	6561（100%）

可以验证 $3^8 = 6561$。

两类 token：语义 token 与声学 token



	声学 **token**	语义 **token**
怎么来	编解码器，以重建波形为目标	自监督模型（HuBERT 等）聚类，或 ASR 编码器量化
保留什么	几乎全部：内容、音色、情绪、噪声	主要是内容和发音，部分韵律
能否直接还原波形	能（解码器）	不能，需要再接一个声学模型
和文本对齐	弱	强，语言模型容易学
代表	EnCodec、DAC	HuBERT k-means、CosyVoice S^3

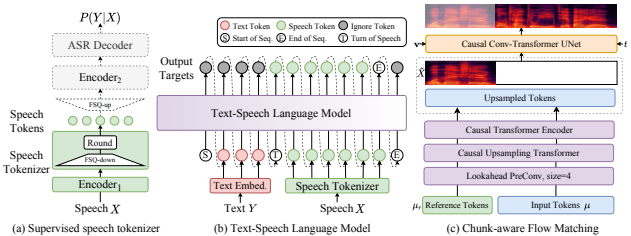
类比

语义 token 像乐谱：记录唱什么、什么节奏。
声学 token 像录音：连谁唱的、在哪唱的都记下来。

混合 token

如 SpeechTokenizer：第 1 层 RVQ 学语义，后几层学声学细节；Spark-TTS 的 BiCodec 把语义和音色分成两种 token。

监督语义 token：让 ASR 来教 token“只记内容”



做法（CosyVoice 系列）

- 取一个训练好的 ASR 模型，把编码器拆成两半
- 中间插入量化层（CosyVoice 用 VQ，CosyVoice 2 用 FSQ）
- 继续用 **ASR** 损失训练：量化后的 token 必须还能被识别成正确文字

结果

token 与文字高度对齐，而且几乎不含说话人信息：CosyVoice 2 用这些 token 训练说话人识别，根本训练不收敛。【回顾】第 04 讲 ASR 与第 06 讲说话人识别在这里交汇。

离散还是连续？没有标准答案

离散 token

优点

- 紧凑，适合语言模型
- 容易与文本、指令统一建模
- 训练稳定，可采样

缺点

- 量化会丢失细节，音质有上限
- token 设计本身是一个难题

连续特征（Mel 或隐变量）

优点

- 保留细节，音质、表现力好
- 不需要额外训练 tokenizer

缺点

- 不能直接用 softmax 预测，需要扩散 / 流匹配
- 计算量大，对数据量要求高

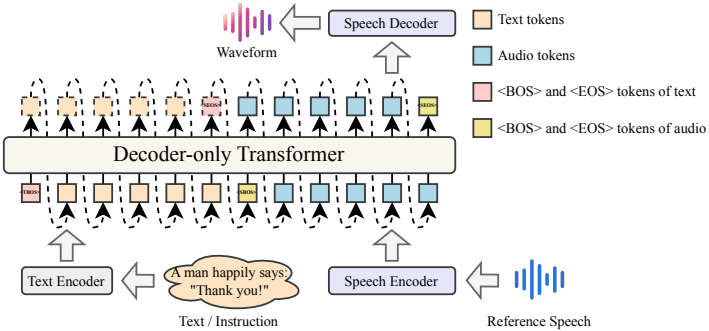
实际系统的折中

用离散 token 做“规划”（说什么、怎么断句），用连续特征做“渲染”（音色、音质）。这就是后面要讲的混合式路线。

目录

1. 端到端合成：VITS
2. 大模型时代：TTS 的新目标与新范式
3. 把语音变成 token
4. 路线一：语言模型式 TTS
5. 路线二：流匹配式 TTS
6. 路线三：混合式 TTS
7. 可控语音合成
8. 大模型 TTS 怎么评价
9. 前沿方向与安全伦理
10. 总结

语言模型式 TTS 的通用结构



序列怎么拼

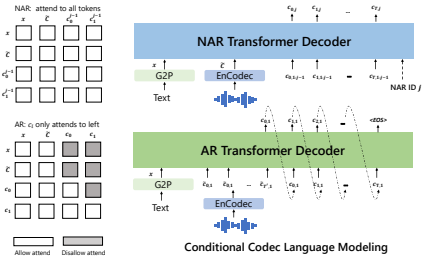
[文本 token] [BOS] [语音 token] [EOS]

训练：和 GPT 一样，预测下一个语音 token，用交叉熵损失。
推理：给出文本和参考语音的 token，让模型“续写”。

四个难题由谁回答

①读什么：模型直接从文本 token 学
②读多长：生成到 EOS 为止
③怎么读：从分布中采样 + 模仿提示
④怎么发声：编解码器的解码器

VALL-E（2023）



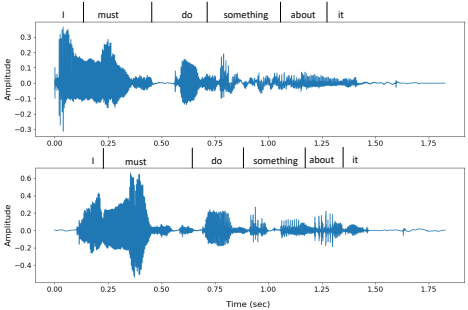
两阶段生成 8 层 EnCodec token

- **AR** 模型：逐帧生成第 1 层 token（决定内容和节奏）
- **NAR** 模型：已知前 $i-1$ 层，并行生成第 i 层 $(i=2,\ldots,8)$

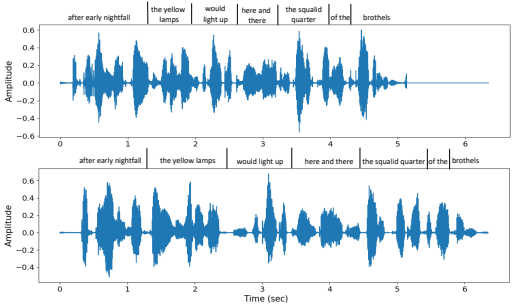
关键：规模

- LibriLight：6 万小时、7000 多位说话人
- 原始数据没有文本，用 ASR 自动转写
- 涌现出上下文学习能力：3 秒提示即可克隆

同一句话，每次都不一样



“I must do something about it”，两次采样



长句的两次采样：停顿位置、语速都不同

为什么会不同

AR 模型每一步都从分布中采样，而不是取概率最大的 token。每次走出的路径不同，节奏、停顿也就不同。

这正是难题③的答案

一对多不再是“需要避免的平均”，而是“可以采样的多样性”。【回顾】第 07 讲 VITS 用随机时长达到类似效果，这里做得更彻底。

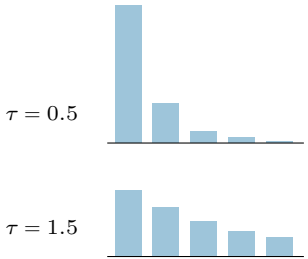
怎么采样？温度与 top-k / top-p

常用采样策略

- 贪心：每步取概率最大的 token
- 温度 τ：$p_k \propto \exp(\ell_k/\tau)$，$\tau$ 越大越随机
- **top-k**：只在概率最高的 k 个里采样
- **top-p**：只在累计概率达到 p 的最小集合里采样

一个反直觉的现象

VALL-E 论文发现：用束搜索（**beam search**）找“概率最高”的序列，反而容易让模型陷入无限循环，一直重复。所以 TTS 通常用采样，不用束搜索。



温度低：几乎总选同一个 token
温度高：更多样，但更容易出错

老问题又回来了：自回归的鲁棒性

典型错误（与 Tacotron 2 相同）

- 漏读、重复：注意力“走丢”
- 停不下来：迟迟不生成结束符
- 时长难控：一个一个生成，事先不知道多长
- 慢：10 秒语音要串行生成数百步

难例长什么样

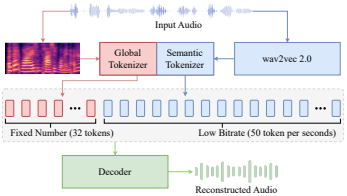
右图是网络小说中的真实文本：同一短语重复十几遍。模型很容易数错次数、提前结束或无限重复。

【嗡嘛呢叭咩吽，嗡嘛呢叭咩吽，嗡嘛呢咩吽，嗡嘛呢叭咩吽，嗡嘛呢叭咩吽，嗡嘛呢叭咩吽，嗡嘛呢叭咩吽...】

常见的改进方法

- 用语义 **token**，降低帧率
- 用预训练文本 LLM 初始化
- 多次采样，用 ASR 挑 CER 最低的
- 强化学习：用 ASR 和说话人相似度作奖励

Spark-TTS（2025）：一个 LLM 直接生成单流 token



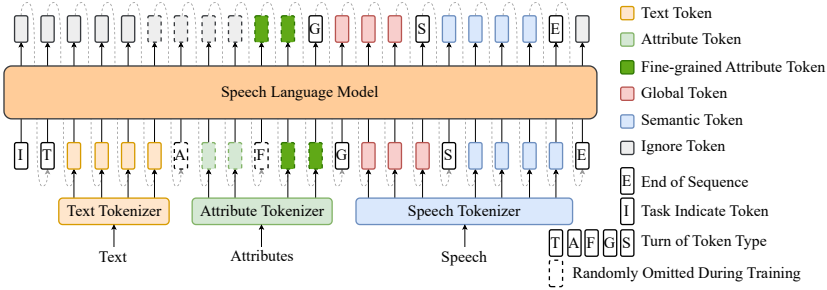
BiCodec：把语音拆成两种 token

- 语义 **token**：每秒 50 个，来自 wav2vec 2.0 特征，记录内容
- 全局 **token**：固定 32 个，与语音长短无关，记录音色等全局属性（FSQ 量化）

好处

- 只有一路 token，不需要 VALL-E 那样的多层预测
- BiCodec 解码器直接出波形，不需要额外的声学模型
- 用 Qwen2.5-0.5B 作为骨干，和文本 LLM 完全一致

Spark-TTS：先“想好”属性，再开口



链式生成（类似 Chain-of-Thought）

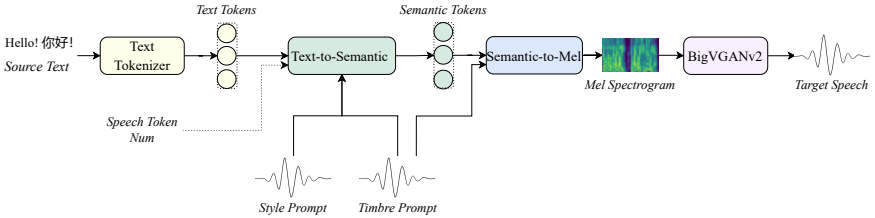
1. 输入粗粒度标签：性别、音高等级、语速等级
2. 模型先预测精确数值：具体音高、具体语速
3. 再生成 32 个全局 token（音色）
4. 最后生成语义 token（内容）

两种用法

克隆：全局 token 直接从参考音频提取。
创造新声音：没有参考音频，只给属性标签，让模型“想象”一个声音。

训练数据 VoxBox：约 10 万小时，自动标注了性别、音高、语速。

IndexTTS2（2025）：自回归也要精确控时长



需求：视频配音

译制片里，配音必须和画面里的口型、镜头时长对齐。自回归模型“想说多长就说多长”，满足不了。

结构：三段式

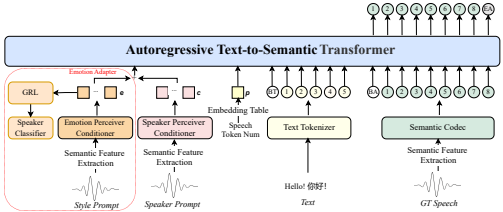
文本 → 语义 **token**（AR）→ **Mel**（NAR）→ BigVGANv2 声码器

做法：告诉模型要生成几个 token

在输入序列中加入一个“目标 token 数”的嵌入 $p = W_{\text{num}}\, h(T)$，训练模型恰好生成 T 个 token。

不需要控时长时，令 $p = \mathbf{0}$，自由生成。

IndexTTS2：音色和情感分开控制



两个提示

- 音色提示：A 的录音 → “用谁的声音”
- 风格提示：B 生气时的录音 → “用什么情绪”

结果：A 的声音 + B 的愤怒。关键是让情感向量里不含说话人信息（用梯度反转层，后面“属性解耦”一节详细讲）。

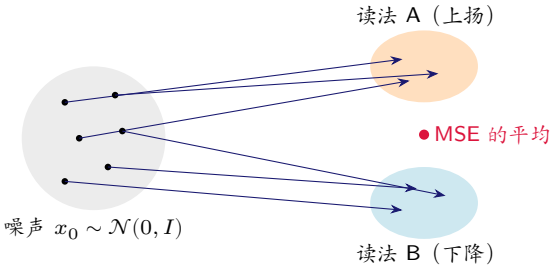
用一句话控制情感

1. 定义 7 种基本情感（愤怒、高兴、恐惧、厌恶、悲伤、惊讶、中性）
2. 用 DeepSeek-R1 给文本描述标注情感概率分布
3. 蒸馏到小模型 Qwen3-1.7B
4. 按概率加权组合情感向量，可表达“悲伤中带点愤怒”

目录

1. 端到端合成：VITS
2. 大模型时代：TTS 的新目标与新范式
3. 把语音变成 token
4. 路线一：语言模型式 TTS
5. 路线二：流匹配式 TTS
6. 路线三：混合式 TTS
7. 可控语音合成
8. 大模型 TTS 怎么评价
9. 前沿方向与安全伦理
10. 总结

从噪声“走”到数据：流匹配的直觉



核心想法

从一个随机噪声点出发，沿着一个速度场移动，最终到达一个真实数据点。不同的起点到达不同的读法。

最简单的路径：直线

训练时随机配对噪声 x_0 和数据 x_1：

$$x_t = (1-t)\,x_0 + t\,x_1, \quad t \in [0,1]$$

沿直线走，速度处处等于 $x_1 - x_0$。

流匹配：训练与推理

训练：学会“该往哪走”

1. 取一段真实 Mel x_1，采样噪声 x_0 和时间 $t \sim U[0,1]$
2. 算出中间点 $x_t = (1-t)x_0 + tx_1$
3. 让网络预测速度，和真实速度比较：

$$\mathcal{L} = \left\| v_\theta(x_t, t, \text{条件}) - (x_1 - x_0) \right\|^2$$

条件：文本、参考语音等

推理：一步步走过去

从噪声 x_0 出发，用欧拉法走 N 步：

$$x_{t+\Delta} = x_t + \Delta \cdot v_\theta(x_t, t, \text{条件})$$

N 称为 **NFE**（网络调用次数），通常 10–32 步。步数越少越快。

分类器无关引导（CFG）

训练时随机丢掉条件；推理时把“有条件”和“无条件”的速度做外推，让输出更贴合文本和音色。

课堂练习：一维流匹配

题目

一维情形：噪声样本 $x_0 = -1$，数据样本 $x_1 = 3$。

1. 求 $t = 0.5$ 时的中间点 $x_{0.5}$，以及训练目标速度。
2. 假设网络学得完美，从 $x_0 = -1$ 出发，用 2 步欧拉法（$\Delta = 0.5$）生成，结果是多少？
3. 如果换一个起点 $x_0' = 1$，而它在训练中被配对到另一个数据点 $x_1' = -2$，会生成什么？

课堂练习：一维流匹配

题目

一维情形：噪声样本 $x_0 = -1$，数据样本 $x_1 = 3$。

1. 求 $t = 0.5$ 时的中间点 $x_{0.5}$，以及训练目标速度。
2. 假设网络学得完美，从 $x_0 = -1$ 出发，用 2 步欧拉法（$\Delta = 0.5$）生成，结果是多少？
3. 如果换一个起点 $x_0' = 1$，而它在训练中被配对到另一个数据点 $x_1' = -2$，会生成什么？

解答

1. $x_{0.5} = 0.5 \times (-1) + 0.5 \times 3 = 1$；目标速度 $x_1 - x_0 = 4$
2. $-1 \xrightarrow{+0.5\times4} 1 \xrightarrow{+0.5\times4} 3$，恰好到达数据点
3. 走到 -2。不同的噪声起点 $\rightarrow$ 不同的结果，这就是流匹配处理一对多的方式

注意：真实情况下，同一个 x_t 可能对应多条直线，网络学到的是这些速度的平均，所以路径会弯曲，需要多走几步。

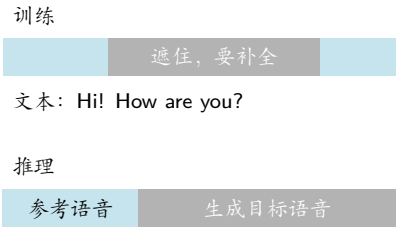
把 TTS 变成“填空题”：语音补全

Voicebox（2023）的想法

训练时把一段 Mel 频谱随机遮住 **70%–100%**，给出完整文本和没遮住的部分，让模型把遮住的部分补出来。

零样本 TTS 就是一道特殊的填空题

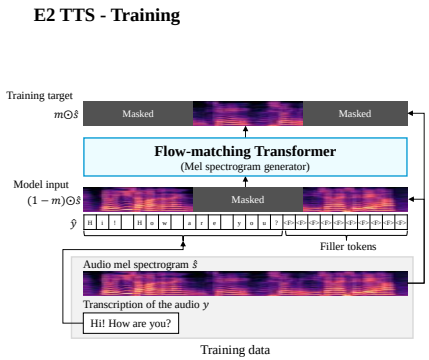
- 没遮住的部分 = 参考语音（提供音色）
- 遮住的部分 = 要合成的语音
- 文本 = 参考文本 + 目标文本

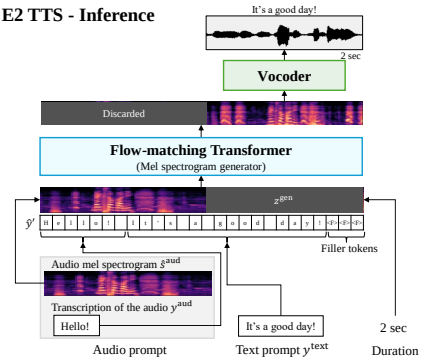


但

Voicebox 仍然需要音素对齐器和时长模型（难题②），流程复杂。

E2 TTS（2024）：“简单到尴尬”的 TTS





唯一的技巧：填充 token

把字符序列用填充符 $\langle F \rangle$ 补到和 Mel 帧数一样长：

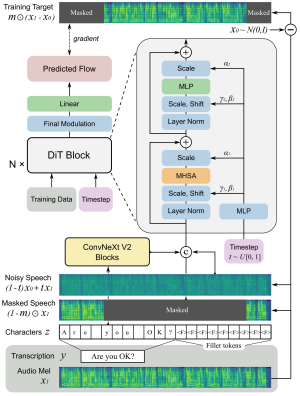
$$(c_1, \dots, c_M, \underbrace{\langle F \rangle, \dots, \langle F \rangle}_{T-M})$$

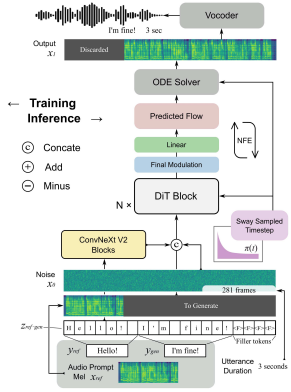
不再需要

G2P、音素对齐、时长预测、MAS……
模型自己学会每个字该占多少帧。

唯一要提供的：生成语音的总时长 T。

F5-TTS（2024）：让 E2 TTS 更稳、更快





三个改进

- **ConvNeXt V2** 文本模块：文本先单独建模，再与语音拼接，对齐更稳
- **DiT** 骨干：扩散 Transformer，替代 U-Net 式结构
- **Sway** 采样：推理时把更多步数放在开头（t 小处），因为开头决定了整体轮廓和对齐

结果

约 3.4 亿参数，用 Emilia 中约 9.5 万小时中英文数据训练；16 步推理 RTF 0.15。代码与模型全部开源。

课堂练习：总时长从哪来？

F5-TTS 的做法：按字数比例估计

假设语速和参考语音一样：

$$T_{\text{gen}} = T_{\text{ref}} \times \frac{\text{目标文本字数}}{\text{参考文本字数}}$$

题目

参考语音 3 秒，参考文本 12 个字；目标文本 20 个字。采样率 24 kHz，帧移 256 点。
(1) 估计目标语音时长；(2) 送入模型的总 Mel 帧数是多少？

课堂练习：总时长从哪来？

F5-TTS 的做法：按字数比例估计

假设语速和参考语音一样：

$$T_{\text{gen}} = T_{\text{ref}} \times \frac{\text{目标文本字数}}{\text{参考文本字数}}$$

题目

参考语音 3 秒，参考文本 12 个字；目标文本 20 个字。采样率 24 kHz，帧移 256 点。
(1) 估计目标语音时长；(2) 送入模型的总 Mel 帧数是多少？

(1) $T_{\text{gen}} = 3 \times 20/12 = 5$ 秒
(2) 参考 + 目标共 8 秒：$8 \times 24000/256 = 750$ 帧

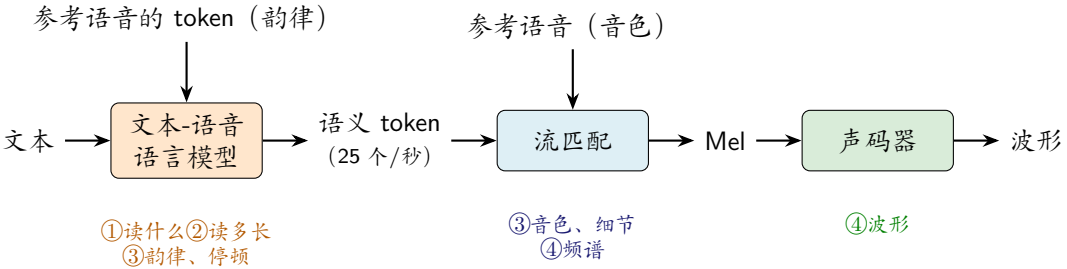
想一想

想读得慢一点，只要把总时长乘 1.2。难题②被分成了两半：总时长由人或简单规则给，每个字的时长由模型自己分配。

目录

1. 端到端合成：VITS
2. 大模型时代：TTS 的新目标与新范式
3. 把语音变成 token
4. 路线一：语言模型式 TTS
5. 路线二：流匹配式 TTS
6. 路线三：混合式 TTS
7. 可控语音合成
8. 大模型 TTS 怎么评价
9. 前沿方向与安全伦理
10. 总结

分工合作：语言模型负责“说什么”，流匹配负责“怎么响”



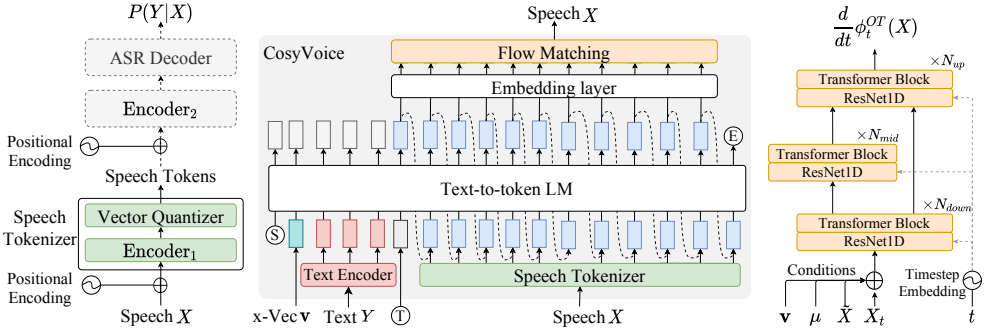
为什么要分两步

语义 token 只有内容、没有音色，语言模型要学的东西少很多，更稳；声学细节交给擅长连续生成的流匹配。

这就是三段式的回归

文本前端 → 声学模型 → 声码器，变成了 **LM** → 流匹配 → 声码器。代表：CosyVoice 系列、Seed-TTS、IndexTTS2。

CosyVoice（2024）



(a) 语音 tokenizer

在 SenseVoice ASR 编码器第 6 层后插入 VQ，单码本 4096 个码字，即监督语义 token S^3

(b) 文本到 token 的 LM

输入：说话人向量 + 文本；自回归生成语义 token

(c) 条件流匹配

语义 token + 说话人向量 + 参考 Mel → Mel 频谱，再由 HiFi-GAN 生成波形

CosyVoice 2：每一步改进各带来多少收益？

模型（Seed-TTS 测试集）	test-zh CER (%) ↓	test-en WER (%) ↓	test-hard WER (%) ↓
CosyVoice	3.63	4.29	11.75
＋ 用预训练文本 LLM（Qwen2.5-0.5B）初始化	2.96	4.57	9.94
＋ 去掉 LM 中的说话人向量	2.56	3.81	9.66
＋ VQ 换成 FSQ（= CosyVoice 2）	**1.45**	**2.57**	**6.83**

数据来源：Z. Du et al., CosyVoice 2, arXiv:2412.10117, Table 5

读表练习

- 哪一步对中文收益最大？

CosyVoice 2：每一步改进各带来多少收益？

模型（Seed-TTS 测试集）	test-zh CER (%) ↓	test-en WER (%) ↓	test-hard WER (%) ↓
CosyVoice	3.63	4.29	11.75
＋ 用预训练文本 LLM（Qwen2.5-0.5B）初始化	2.96	4.57	9.94
＋ 去掉 LM 中的说话人向量	2.56	3.81	9.66
＋ VQ 换成 FSQ（= CosyVoice 2）	**1.45**	**2.57**	**6.83**

数据来源：Z. Du et al., CosyVoice 2, arXiv:2412.10117, Table 5

读表练习

- 哪一步对中文收益最大？换 FSQ，CER 从 2.56 降到 1.45
- 为什么去掉说话人向量反而更好？

CosyVoice 2：每一步改进各带来多少收益？

模型（Seed-TTS 测试集）	test-zh CER (%) ↓	test-en WER (%) ↓	test-hard WER (%) ↓
CosyVoice	3.63	4.29	11.75
＋ 用预训练文本 LLM（Qwen2.5-0.5B）初始化	2.96	4.57	9.94
＋ 去掉 LM 中的说话人向量	2.56	3.81	9.66
＋ VQ 换成 FSQ（= CosyVoice 2）	**1.45**	**2.57**	**6.83**

数据来源：Z. Du et al., CosyVoice 2, arXiv:2412.10117, Table 5

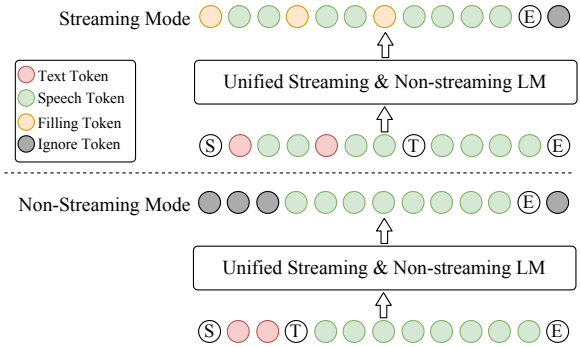
读表练习

- 哪一步对中文收益最大？换 FSQ，CER 从 2.56 降到 1.45
- 为什么去掉说话人向量反而更好？说话人向量里还混有语言、情绪信息，会“泄露”给 LM，干扰它模仿参考语音

其他变化

直接输入 BPE 文本，不再做 G2P；token 降到每秒 25 个；训练数据约 17 万小时（中文 13 万）。

流式合成：边想边说



文本与语音交错

每读入 $N = 5$ 个文本 token，就生成 $M = 15$ 个语音 token。上游 LLM 一边生成文字，TTS 一边开口。

首包延迟

用户听到第一段声音前的等待时间：

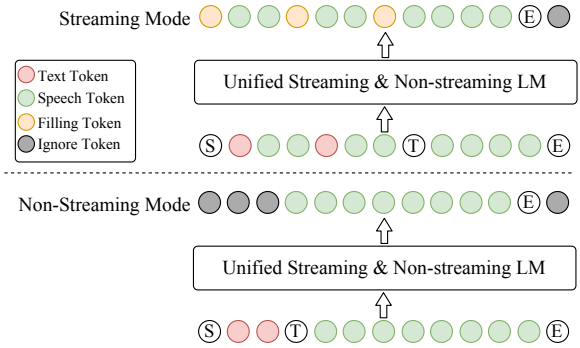
$$L_{\text{TTS}} = M\,(d_{\text{lm}} + d_{\text{fm}} + d_{\text{voc}})$$

d：每个语音 token 在 LM、流匹配、声码器中的计算时间

练习

设 $d_{\text{lm}} = 10$ ms，$d_{\text{fm}} = 5$ ms，$d_{\text{voc}} = 2$ ms（假设值），$M = 15$，token 率 25/秒。首包延迟多少？首包包含多长的音频？

流式合成：边想边说



文本与语音交错

每读入 $N = 5$ 个文本 token，就生成 $M = 15$ 个语音 token。上游 LLM 一边生成文字，TTS 一边开口。

首包延迟

用户听到第一段声音前的等待时间：

$$L_{\text{TTS}} = M\left(d_{\text{lm}} + d_{\text{fm}} + d_{\text{voc}}\right)$$

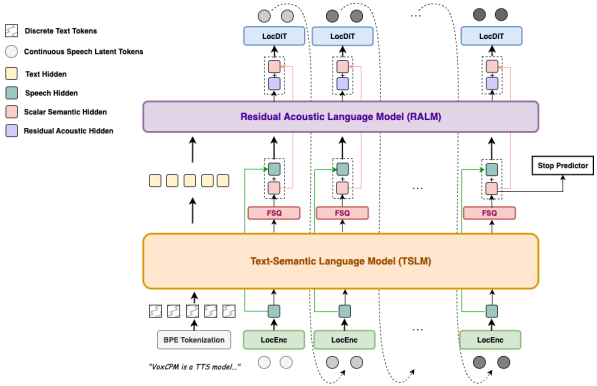
d：每个语音 token 在 LM、流匹配、声码器中的计算时间

练习

设 $d_{\text{lm}} = 10$ ms，$d_{\text{fm}} = 5$ ms，$d_{\text{voc}} = 2$ ms（假设值），$M = 15$，token 率 25/秒。首包延迟多少？首包包含多长的音频？

$L = 15 \times 17 = 255$ ms；首包音频 $15/25 = 0.6$ 秒。生成比播放快，后面就不会卡顿。

另一种思路：不用外部 tokenizer（VoxCPM，2025）



动机

离散 token 稳定但丢细节；连续特征保细节但长句容易崩。能否两者兼得？

做法

- 语言模型直接自回归生成连续语音隐变量
- 中间加一个 **FSQ** 瓶颈，只作为内部约束：得到稳定的“语义骨架”
- 另一个模型补上被量化丢掉的残差细节
- 局部扩散 Transformer 输出最终隐变量

依然是“先规划、后渲染”的分工，只是放进了一个可端到端训练的模型里。

三条路线对比

	语言模型式	流匹配式	混合式
代表	VALL-E、Spark-TTS	E2 TTS、F5-TTS	CosyVoice 2、Seed-TTS、IndexTTS2
中间表示	离散 token	连续 Mel	语义 token + Mel
②读多长	生成结束符;或指定 token 数	人为给定总时长	LM 生成结束符
③一对多	从 token 分布采样	从不同噪声出发	两者都有
速度	串行，较慢	并行，10–32 步	LM 串行 + 流匹配并行
流式	天然支持	较难（要先知道总长）	支持（分块）
主要问题	漏读、重复、停不下来	总时长要估计；对齐可能失败	系统较复杂，两个模型

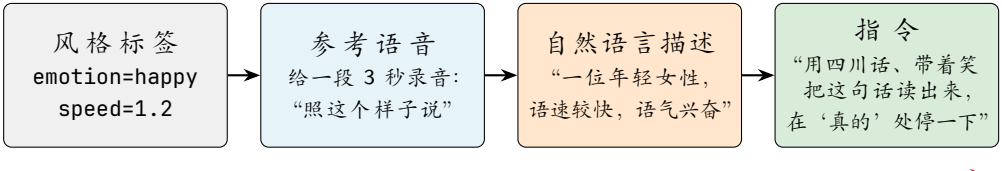
没有“最好”，只有“最合适”

实时对话要流式 → 语言模型式或混合式；视频配音要精确时长 → 流匹配式，或能控 token 数的 AR 模型；离线有声书追求质量和稳定 → 混合式。

目录

1 端到端合成：VITS
2 大模型时代：TTS 的新目标与新范式
3 把语音变成 token
4 路线一：语言模型式 TTS
5 路线二：流匹配式 TTS
6 路线三：混合式 TTS
7 可控语音合成
8 大模型 TTS 怎么评价
9 前沿方向与安全伦理
10 总结

控制信号的演进：从“选项”到“对话”



早期

只能控制预先定义好的少数属性，每个属性要有对应的标注数据。

现在

借助大语言模型理解任意描述和指令，控制方式与聊天机器人一致。

分类参考：T. Xie et al., arXiv:2412.06602

方式一：风格标签

三种形式

- 离散标签：开心 / 生气 / 悲伤；男 / 女
- 连续数值：音高 +20%、语速 0.8 倍
- 修改隐变量：在学到的风格空间里移动

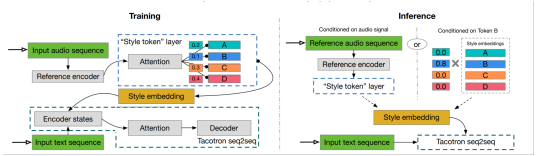
【回顾】FastSpeech 2 直接改音高、能量、时长，就是连续数值控制。

大模型时代的“标签”：细粒度标记

CosyVoice 2 支持在文本中插入标记：

他说 [laughter] 这也太好笑了

我 真的 不知道



GST：学一组“风格 token”，推理时选择或加权组合

局限

简单、精确，但只能控制预先定义的少数属性，无法表达“带着哭腔强装镇定”这样复杂的要求。

方式二：参考语音提示

做法

零样本 TTS 的标准用法：给一段参考语音，模型模仿它的音色、口音、语速和情绪。

问题：照单全收

参考语音里的一切都可能被复制：

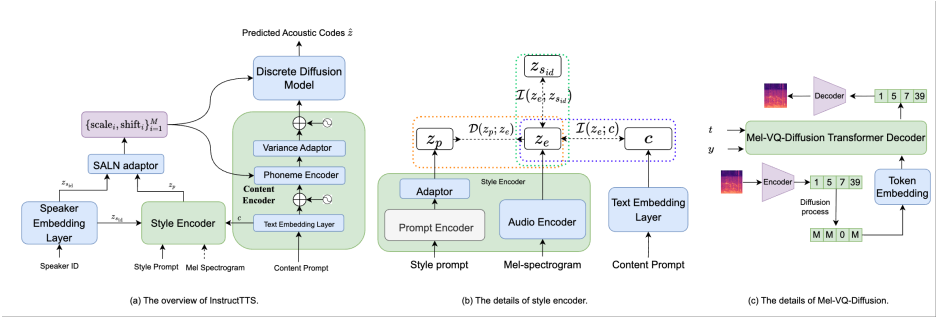
- 录音环境的噪声和混响
- 当时的情绪（想要开心的声音，参考却是平淡的）
- 特殊的语速和停顿习惯

改进：拆开不同的参考

- IndexTTS2：音色提示 + 风格提示，分别来自两段录音
- Spark-TTS：只取参考语音的全局 token（音色），内容和节奏由模型生成
- MegaTTS 2、NaturalSpeech 3：把语音分解成内容、韵律、音色等独立部分

关键能力：属性解耦，本节稍后讲。

方式三：自然语言描述



做法

输入分成两部分：内容（要读的文字）+ 描述（“叹着气，满是悲伤和无奈”）。用文本编码器理解描述，作为生成条件。

代表

PromptTTS（2023）、InstructTTS（2024）、Parler-TTS（2024，用自动生成的描述训练）

难点：描述和声音如何对应？需要大量“语音-描述”配对数据。

方式四：指令式合成与编辑

指令式合成

不再区分“内容”和“描述”，像和聊天机器人说话一样，一条指令说清所有要求：

> 用开心的语气、四川话说：今天终于放假啦！

代表：VoxInstruct、CosyVoice 2 的指令模式（约 1500 小时指令数据，覆盖情感、语速、方言、角色扮演）、Step-Audio

指令式编辑

已经有一段录音，只想改其中一个词：

- “把‘周三’改成‘周四’”
- 插入、删除、替换，其余部分保持原样

代表：VoiceCraft（2024）

现状

能听懂指令，但常常不完全照做，需要多次生成挑选。指令遵循能力仍是研究热点。

四种控制方式对比

方式	核心思想	优点	缺点
风格标签	用预定义标签控制特定属性	简单、精确	表达有限，难以组合
参考语音	用一段录音示范	个性化程度高，支持克隆	依赖录音质量；控制维度不直观
自然语言描述	用文字描述想要的声音	直观、易用	描述不精确，模型可能误解
指令	LLM 理解自由指令	最灵活，可生成笑声等副语言	依赖 LLM，系统复杂

整理自： T. Xie et al., arXiv:2412.06602, Table 4

实际系统往往组合使用

例如：参考语音定音色 + 指令定情绪 + 细粒度标记加笑声 + 指定 token 数定时长。

属性解耦：可控的前提

属性彼此缠绕

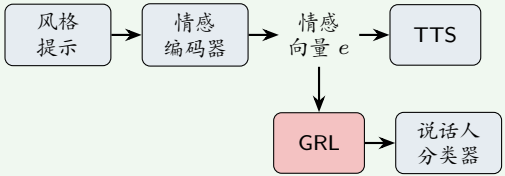
- 生气时：音高升高、语速加快、声音变粗
- 同一个人开心和悲伤，“音色”听起来也不同
- 改音高，可能连情绪一起改了

想“只换情绪不换人”，就要把它们拆开表示。

方法二：信息瓶颈

让某个分支的容量很小，只能装下一种信息。例如 CosyVoice 的语义 token 经过量化，装不下说话人信息。

方法一：对抗训练（梯度反转层 GRL）



分类器努力从 e 中猜出是谁在说话；GRL 把梯度取反传回编码器，编码器于是学着让分类器猜不出来。最终 e 中只剩情感，不含说话人信息。

【回顾】与第 07 讲 GAN 的“生成器骗判别器”是同一个思想。

数据：可控 TTS 的最大瓶颈

类型	数据集	规模	语言
情感标签	ESD	29 小时	中、英
	IEMOCAP	12 小时	英
文本描述	TextrolSpeech	330 小时	英
	SpeechCraft	2391 小时	中、英
	Parler-TTS 数据	5 万小时	英
对话	MagicData-RAMC	180 小时	中
	DailyTalk	20 小时	英

来源：T. Xie et al., arXiv:2412.06602, Table 5

难在哪

情感等主观属性人工标注贵、不一致；大多只有粗标签；同一说话人在不同情绪下的录音很少。

自动标注流水线

1. 用现成模型提取属性：
   性别、年龄（分类器）
   音高（PyWorld 等）
   语速（音节数 / 时长）
   情感（情感识别模型）
2. 把属性离散成等级（如 5 档音高）
3. 让大语言模型把属性写成自然语言描述

Spark-TTS 的 VoxBox、Parler-TTS 都用了类似思路

课堂讨论：你会怎么选？

为下面四个场景各选一种技术路线和控制方式，并说明理由

1. 把一部英文纪录片配成中文，保留原解说员的声音
2. 有声书平台：一本小说有 30 个角色
3. 车载语音助手：要求一开口就快速响应
4. 游戏 NPC：根据剧情实时生成带情绪的对白

课堂讨论：你会怎么选？

为下面四个场景各选一种技术路线和控制方式，并说明理由

1. 把一部英文纪录片配成中文，保留原解说员的声音
2. 有声书平台：一本小说有 30 个角色
3. 车载语音助手：要求一开口就快速响应
4. 游戏 NPC：根据剧情实时生成带情绪的对白

参考思路

1. 跨语言零样本克隆 + 时长可控（流匹配，或 IndexTTS2 类 AR 模型）
2. 每个角色一段参考语音或一句描述；离线生成，选质量最好的混合式模型
3. 流式混合式或 LM 式，关注首包延迟
4. 指令式控制情绪，流式输出；还要考虑本地部署的算力

目录

1. 端到端合成：VITS
2. 大模型时代：TTS 的新目标与新范式
3. 把语音变成 token
4. 路线一：语言模型式 TTS
5. 路线二：流匹配式 TTS
6. 路线三：混合式 TTS
7. 可控语音合成
8. 大模型 TTS 怎么评价
9. 前沿方向与安全伦理
10. 总结

评价的基本工具

主观评价：请人来听

- **MOS**：1–5 分，自然度（N-MOS）
- **SMOS**：和参考说话人像不像
- **CMOS**：两个系统听同一句，$-3 \sim +3$ 比较
- **AB / ABX**：哪个更好 / 哪个更像参考

要报告置信区间；不同论文的 MOS 不能直接比

客观评价：让机器来测

维度	指标	怎么算
可懂度	CER / WER	ASR 转写合成语音，与输入文本比较（第 04 讲）
相似度	SIM	说话人嵌入的余弦相似度（第 06 讲）
自然度	UTMOS 等	神经网络预测 MOS
效率	RTF、首包延迟	合成耗时 / 音频时长

零样本 TTS 最常报告的三个数：**CER/WER**、**SIM**、**RTF**。

零样本 TTS 的“标准考卷”：Seed-TTS-eval

三份试卷

- **test-en**：约 1000 句英文（来自 Common Voice）
- **test-zh**：约 2000 句中文（来自 DiDiSpeech）
- **test-hard**：约 400 句中文难例：文本重复、绕口令等

每句配一段参考语音（提供音色）和一段目标文本。

阅卷方式

- 英文 WER：Whisper-large-v3 识别
- 中文 CER：Paraformer 识别
- SIM：基于 WavLM 的说话人验证模型

测试集、参考语音、识别模型都公开，不同论文的结果才可以比较。

`https://github.com/BytedanceSpeech/seed-tts-eval`

成绩单（截至 2024 年底）

模型	路线	test-zh CER ↓	test-en WER ↓	test-hard WER ↓
真人录音	–	1.26	2.14	–
Seed-TTS†	混合式	1.12	2.25	7.59
MaskGCT	非自回归（掩码生成）	2.27	2.62	10.27
E2 TTS†	流匹配	1.97	2.19	–
F5-TTS	流匹配	1.56	1.83	8.67
CosyVoice	混合式	3.63	4.29	11.75
CosyVoice 2	混合式	1.45	2.57	6.83

† 闭源模型。数据来源：Z. Du et al., CosyVoice 2, arXiv:2412.10117, Table 3（单位：%）

能读出什么

普通句子上，最好的模型错误率已经接近甚至低于真人录音；差距主要在 test-hard 这类难例上。

思考

合成语音的 CER 比真人还低，说明它比真人“说得更好”吗？

读成绩单的陷阱

陷阱 1：ASR 偏爱“标准”的声音

CosyVoice 2 论文发现：基础模型的语速比真人慢，反而更容易被 ASR 识别。**CER** 低可能只是读得慢、读得平。

陷阱 2：换个评委，分数就变

同一个 F5-TTS 在 test-en 上的 SIM：用 WavLM 模型测是 0.647，用 ERes2Net 测是 0.742。不同论文用不同模型，SIM 不可比。

陷阱 3：考卷不一样

同样叫“LibriSpeech test-clean”，不同论文挑的句子数从几十到一千多句不等，参考语音也不同。

陷阱 4：只考短句

测试句大多只有几秒。有声书、播客需要的长文本连贯性、情感一致性几乎没有被评价。

结论

客观指标用来快速筛选，最终还要听，而且要在同一条件下比较。

新问题：怎么评价“是否听从了指令”？

CER、SIM 都测不了

“用悲伤的语气读”——读得悲不悲伤？CER 只管字对不对，SIM 只管像不像。

尝试：让多模态大模型当评委

综述作者让 Gemini 听合成语音，按 1–5 分给三个维度打分：

- 指令遵循：是否按要求的情绪、节奏读
- 自然度：像不像真人
- 表现力：情感是否丰富

与人工评分的相关系数（Pearson）

	指令遵循	自然度	表现力
NISQA	–	0.01	−0.03
UTMOS	–	−0.10	−0.17
Gemini 评委	0.12	0.17	0.14

来源：T. Xie et al., arXiv:2412.06602, Table 8

怎么理解

传统 MOS 预测器在富有表现力的语音上几乎失效；大模型评委好一些，但相关性仍然很低。可控 TTS 的自动评价还是开放问题。

目录

1. 端到端合成：VITS
2. 大模型时代：TTS 的新目标与新范式
3. 把语音变成 token
4. 路线一：语言模型式 TTS
5. 路线二：流匹配式 TTS
6. 路线三：混合式 TTS
7. 可控语音合成
8. 大模型 TTS 怎么评价
9. 前沿方向与安全伦理
10. 总结

仍未解决的挑战

细粒度控制

能控制整句的情绪，但难以精确控制“第三个词重读、最后一个字上扬”。

需要更细的标注和更强的模型

属性解耦

音高、情绪、音色相互影响；讽刺、犹豫这类微妙的语气更难拆分和控制。

对抗训练、信息瓶颈都不完美

数据稀缺

缺少场景丰富（喜剧、惊悚、卡通）、标注精细、同一人多种状态的数据。

人工标注贵且主观

整理自：T. Xie et al., arXiv:2412.06602, Sec. 5

未来方向

1. 指令驱动的细粒度合成与编辑

用自然语言精确地修改一段语音的局部，一次就做对。

2. 多模态语音合成

看图配音、看视频配音：根据画面里人物的表情、口型、场景生成合适的声音。

3. 长文本与对话合成

有声书：几十分钟内音色、情感保持一致。
对话 / 播客：多人轮流说话，有自然的接话、笑声和打断。

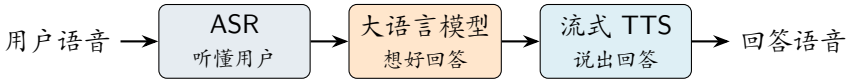
4. 大规模数据自动构建

用识别、分析模型自动标注属性，用大语言模型生成描述和编辑指令，甚至用多智能体生成长篇对话数据。

一个更大的趋势：TTS 成为大模型的“嘴”

语音对话系统（如 GPT-4o 类产品）中，TTS 负责把大模型的回答说出来。要求：流式、低延迟、能根据对话上下文选择合适的语气。

TTS 走进语音对话：延迟从哪来



级联系统的首包延迟

大模型生成前 N 个文本 token 后，TTS 就开始工作：

$$L_{\text{Chat}} \le N\, d_{\text{llm}} + L_{\text{TTS}}$$

d_{llm}：大模型生成一个文本 token 的时间

更进一步

端到端语音大模型直接输出语音 token，省掉中间的文本环节。但内部仍然需要“语音 token → 波形”的生成模块，也就是本讲的技术。

【回顾】第 04 讲 ASR、本讲 TTS、第 06 讲说话人建模，最终在语音对话系统中汇合。

技术之外：安全与伦理

风险

- 几秒钟录音就能克隆一个人的声音
- 电话诈骗、冒充身份、伪造录音
- 未经授权使用他人声音，侵犯声音权益
- 攻击声纹识别系统（联系第 06 讲）
- 训练数据来源不透明，可能缺少授权

应对

- 知情同意：采集和使用声音需获得本人授权
- 标识：《人工智能生成合成内容标识办法》自 2025 年 9 月起施行，要求对合成语音等内容添加标识
- 技术手段：音频水印、合成语音检测
- 评测：把滥用风险、偏见（口音、性别）纳入评价

与课程项目的联系

本课程的 Project 选题中包含“合成语音检测”和“方言 TTS”，欢迎感兴趣的同学结合本讲内容选择。

目录

1. 端到端合成：VITS
2. 大模型时代：TTS 的新目标与新范式
3. 把语音变成 token
4. 路线一：语言模型式 TTS
5. 路线二：流匹配式 TTS
6. 路线三：混合式 TTS
7. 可控语音合成
8. 大模型 TTS 怎么评价
9. 前沿方向与安全伦理
10. 总结

四个核心难题，三代解决方案

难题	传统方法	神经网络 **TTS**	大模型 **TTS**
①读什么	规则 + 词典	神经 G2P、多音字消歧	直接输入字符 / BPE，从海量数据中学
②读多长	HMM 状态时长	注意力 / 时长预测 / MAS	结束符；指定 token 数；给定总时长
③怎么读	统计平均（过平滑）	补充音高能量 + 生成模型	采样 + 参考语音提示 + 描述和指令
④怎么发声	拼接 / 源-滤波器	WaveNet → HiFi-GAN	编解码器解码器；流匹配 + 声码器

方法在变，问题不变。抓住问题，就能读懂任何一个新模型。

本讲小结

1. VITS 把声学模型和声码器联合训练，用 MAS 自动对齐，解决了两阶段的不匹配
2. 大模型时代的新目标：零样本、可控、规模化、流式
3. 语音 token：VQ 找最近码字；RVQ 逐层补残差；FSQ 直接取整。语义 token 记内容，声学 token 记一切
4. 语言模型式（VALL-E、Spark-TTS）：采样解决一对多，但有鲁棒性和时长问题
5. 流匹配式（E2 / F5-TTS）：从噪声沿速度场走到数据，结构极简，需给定总时长
6. 混合式（CosyVoice 2）：LM 规划内容和节奏，流匹配渲染音色和细节，支持流式
7. 控制方式从标签、参考语音发展到描述和指令，关键在属性解耦和数据
8. 评价要在同一考卷、同一评委下比较；指令遵循和表现力的自动评价仍是开放问题

带走的一句话

大模型 TTS 的本质，是把“读出一段文字”变成了“根据提示续写一段语音”。

课后思考题

1. 用 EnCodec（75 帧/秒，8 层 RVQ）表示 1 分钟语音需要多少个 token？如果改用 CosyVoice 2 的语义 token（25 个/秒，单层），是多少？这对自回归语言模型意味着什么？
2. VALL-E 和 F5-TTS 分别怎样解决“一对多”问题？二者在“读多长”上各有什么优缺点？
3. CosyVoice 2 去掉语言模型中的说话人向量后，音色信息由谁提供？为什么这样做反而提升了内容准确率？
4. 请设计一个实验，判断某个零样本 TTS 模型在“参考语音很生气、但指令要求开心”时，听从的是参考语音还是指令。你会用哪些指标？
5. 如果你是一家有声书平台的工程师，请分别列出采用零样本克隆技术的两个好处和两个风险，并给出应对风险的办法。

动手试一试与推荐阅读

开源模型（均提供代码与权重）

- **CosyVoice**：https://github.com/FunAudioLLM/CosyVoice
- **F5-TTS**：https://github.com/SWivid/F5-TTS
- **Spark-TTS**：https://github.com/SparkAudio/Spark-TTS
- **IndexTTS**：https://github.com/index-tts/index-tts
- **VoxCPM**：https://github.com/OpenBMB/VoxCPM

推荐阅读

- T. Xie et al., *Towards Controllable Speech Synthesis in the Era of Large Language Models: A Systematic Survey*, arXiv:2412.06602（本讲“可控合成”部分的主要参考）
- X. Tan et al., *A Survey on Neural Speech Synthesis*, 2021
- C. Wang et al., VALL-E, 2023
- Z. Du et al., CosyVoice 2, 2024
- Y. Chen et al., F5-TTS, 2024

小实验

用自己的声音（只用自己的!）做零样本克隆，用 Paraformer 或 Whisper 测 CER，用说话人模型测 SIM。

参考文献 I

[1] T. Xie et al., "Towards Controllable Speech Synthesis in the Era of Large Language Models: A Systematic Survey," *arXiv:2412.06602*, 2024.

[2] X. Tan, T. Qin, F. Soong, and T.-Y. Liu, "A Survey on Neural Speech Synthesis," *arXiv:2106.15561*, 2021.

[3] Y. Wang et al., "Style Tokens: Unsupervised Style Modeling, Control and Transfer in End-to-End Speech Synthesis," *ICML*, 2018.

[4] J. Kim, J. Kong, and J. Son, "Conditional Variational Autoencoder with Adversarial Learning for End-to-End Text-to-Speech," *ICML*, 2021.

[5] N. Zeghidour et al., "SoundStream: An End-to-End Neural Audio Codec," *IEEE/ACM TASLP*, 2021.

[6] W.-N. Hsu et al., "HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units," *IEEE/ACM TASLP*, 2021.

[7] A. Défossez, J. Copet, G. Synnaeve, and Y. Adi, "High Fidelity Neural Audio Compression," *TMLR*, 2023.

[8] F. Mentzer, D. Minnen, E. Agustsson, and M. Tschannen, "Finite Scalar Quantization: VQ-VAE Made Simple," *ICLR*, 2024.

[9] C. Wang et al., "Neural Codec Language Models are Zero-Shot Text to Speech Synthesizers," *arXiv:2301.02111*, 2023.

[10] Y. Lipman et al., "Flow Matching for Generative Modeling," *ICLR*, 2023.

[11] M. Le et al., "Voicebox: Text-Guided Multilingual Universal Speech Generation at Scale," *NeurIPS*, 2023.

[12] Z. Guo et al., "PromptTTS: Controllable Text-to-Speech with Text Descriptions," *ICASSP*, 2023.

[13] D. Yang et al., "InstructTTS: Modelling Expressive TTS in Discrete Latent Space with Natural Language Style Prompt," *IEEE/ACM TASLP*, 2024.

[14] D. Lyth and S. King, "Natural Language Guidance of High-Fidelity Text-to-Speech with Synthetic Annotations," *arXiv:2402.01912*, 2024.

[15] Z. Ju et al., "NaturalSpeech 3: Zero-Shot Speech Synthesis with Factorized Codec and Diffusion Models," *ICML*, 2024.

[16] P. Anastassiou et al., "Seed-TTS: A Family of High-Quality Versatile Speech Generation Models," *arXiv:2406.02430*, 2024.

[17] S. E. Eskimez et al., "E2 TTS: Embarrassingly Easy Fully Non-Autoregressive Zero-Shot TTS," *IEEE SLT*, 2024.

参考文献 II

[18] Z. Du et al., "CosyVoice: A Scalable Multilingual Zero-shot Text-to-speech Synthesizer based on Supervised Semantic Tokens," *arXiv:2407.05407*, 2024.

[19] Z. Du et al., "CosyVoice 2: Scalable Streaming Speech Synthesis with Large Language Models," *arXiv:2412.10117*, 2024.

[20] P. Peng et al., "VoiceCraft: Zero-Shot Speech Editing and Text-to-Speech in the Wild," *ACL*, 2024.

[21] Y. Zhou et al., "VoxInstruct: Expressive Human Instruction-to-Speech Generation with Unified Multilingual Codec Language Modelling," *ACM MM*, 2024.

[22] Z. Jin et al., "SpeechCraft: A Fine-Grained Expressive Speech Dataset with Natural Language Description," *ACM MM*, 2024.

[23] S. Ji et al., "TextrolSpeech: A Text Style Control Speech Corpus with Codec Language Text-to-Speech Models," *ICASSP*, 2024.

[24] H. He et al., "Emilia: An Extensive, Multilingual, and Diverse Speech Dataset for Large-Scale Speech Generation," *IEEE SLT*, 2024.

[25] Y. Chen et al., "F5-TTS: A Fairytaler that Fakes Fluent and Faithful Speech with Flow Matching," *arXiv:2410.06885*, 2024.

[26] Y. Wang et al., "MaskGCT: Zero-Shot Text-to-Speech with Masked Generative Codec Transformer," *ICLR*, 2025.

[27] X. Wang et al., "Spark-TTS: An Efficient LLM-Based Text-to-Speech Model with Single-Stream Decoupled Speech Tokens," *arXiv:2503.01710*, 2025.

[28] A. Huang et al., "Step-Audio: Unified Understanding and Generation in Intelligent Speech Interaction," *arXiv:2502.11946*, 2025.

[29] S. Zhou et al., "IndexTTS2: A Breakthrough in Emotionally Expressive and Duration-Controlled Auto-Regressive Zero-Shot Text-to-Speech," *arXiv:2506.21619*, 2025.

[30] VoxCPM Team, "VoxCPM: Tokenizer-Free TTS for Context-Aware Speech Generation and True-to-Life Voice Cloning," Technical Report, 2025.

谢谢！

Questions?

欢迎提问与讨论

Email: shuaiwang@nju.edu.cn